



## 1 准备知识

## ② 统计检测基本模型

如果函数  $f(x)$  在区间  $[a, b]$  上连续, 则积分上限函数

$$\Phi(x) = \int_a^x f(t)dt$$

在  $[a, b]$  上具有导数, 并且它的导数是

$$\Phi'(x) = \frac{d}{dx} \int_a^x f(t) dt = f(x) \quad (a \leq x \leq b)$$

## Theorem

如果函数  $f(x)$  在区间  $[a, b]$  上连续, 则函数

$$\Phi(x) = \int_a^x f(t)dt$$

就是  $f(x)$  在  $[a, b]$  上的一个原函数。

如果函数  $F(x)$  是连续函数  $f(x)$  在区间  $[a, b]$  上的一个原函数, 则

$$\int_a^b f(x)dx = F(b) - F(a)$$







$$\mathbf{R} = \bigcup_{i=0}^{M-1} R_i, \quad R_i \cap R_j = \emptyset, (i \neq j)$$

最佳信号检测  $\Leftarrow$  正确划分观测空间  $\mathbf{R}$  中的各个判决域  $R_i \Leftarrow$  最佳检测准则

两种假设先验等概  $\implies P(H_0) = P(H_1) = \frac{1}{2}$

采样样本  $x_i (i = 1, 2, \dots, N)$  之间相互统计独立, 因此其  $N$  维联合概率密度能够表示成各自一维概率密度之积的形式, 即

$$p(x_1, x_2, \dots, x_N) = p(x_1)p(x_2) \cdots p(x_N) = \prod_{i=1}^N p(x_i)$$



如果  $n$  是均值为零的, 方差为  $\sigma_n^2$  的高斯随机变量, 两个假设下的观测信号模型

$$H_0 : r = -1 + n$$

观测信号  $p(r|H_1), p(r|H_0)$  应服从何种分布?

因为高斯随机变量的特点:高斯随机变量的线性组合还是高斯随机变量。

习题 2.7:  $x \sim \mathcal{N}(\mu_x, \sigma_x^2)$ , 则  $(y = ax + b) \sim \mathcal{N}(a\mu_x + b, a^2\sigma_x^2)$ 。

所以,  $p(r|H_1) \sim \mathcal{N}(1, \sigma_n^2)$ ,  $p(r|H_0) \sim \mathcal{N}(-1, \sigma_n^2)$

直接计算:  $E(r|H_0) = E(1 + n) = 1 + E(n) = 1, Var(r|H_0) =$

$$E[(r|H_0 - E(r|H_0))^2] = E[n^2] = \sigma_n^2 \implies r|H_0 \sim \mathcal{N}(1, \sigma_n^2)$$


$$E(r|H_1) = E(-1 + n) = -1 + E(n) = -1, Var(r|H_1) = E[(r|H_1 - E(r|H_1))^2] = E[n^2] = \sigma_n^2 \implies r|H_1 \sim \mathcal{N}(-1, \sigma_n^2)$$

$$n \sim \mathcal{N}(\mathbf{0}, \sigma^2)$$

$$H_0 : x = n \quad x \sim \mathcal{N}(0, \sigma^2)$$

$$H_1 : x = m + n \quad x \sim \mathcal{N}(m, \sigma^2)$$

判决表达式:  $x \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma^2}{m} \ln \eta + \frac{m}{2}$





$p(l|H_j)(j = 0, 1)$ : 假设  $H_j$  下观测信号的概率密度函数;  $r^+ = \frac{\sigma^2}{m} \ln \eta + \frac{m}{2}$ ;  $\alpha = P(H_1|H_0)$

## 思考

- ①  $\frac{m}{2}$  是两个假设的中间值,  $\frac{\sigma^2}{m} \ln \eta$  为中间值的修正量, 其含义如何?
- ② 考虑  $m > 0, m < 0, m = 0$  时, 如何构造判决表达式?

- ①  $m = 0$  时:  $H_0, H_1$  成为一样的信号。
- ②  $m \uparrow \implies$  中间值修正量  $(\frac{\sigma^2}{m} \ln \eta) \downarrow$ ,  $r$  越接近于中间值  $\frac{m}{2}$ 。
- ③  $m$  值越大, 更易区分两种假设, 检测性能越好。
- ④  $m > 0$  和  $m < 0$  下的判决表达式如下图。



$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma^2 \ln \eta}{Nm} + \frac{m}{2} \stackrel{\text{def}}{=} \gamma^+$$


而无论是在假设  $H_0$  下,还是在假设  $H_1$  下,  $(x_i|H_0), (x_i|H_1)$  均服从高斯分布,因为高斯随机变量的线性组合还是高斯随机变量,所以两种假设下的观测量  $(l|H_0), (l|H_1)$  也是服从高斯分布的随机变量。

$$x_i (i = 1, 2, \dots, N)$$

$$n_i \sim \mathcal{N}(0, \sigma^2)$$

$$H_0 : x_i = n_i \quad (l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$$

$$H_1 : x_i = m + n_i \quad (l|H_1) \sim \mathcal{N}(m, \frac{\sigma^2}{N})$$



$p(l|H_j)(j = 0, 1)$ : 假设  $H_j$  下观测信号的概率密度函数;  $r^+ = \frac{\sigma^2 \ln \eta}{Nm} + \frac{m}{2}$ ;  $\alpha = P(H_1|H_0)$

13 / 54

$$Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) du.$$

因为  $P(H_1|H_0) = Q(\ln \eta/d + d/2) \implies \ln \eta/d = Q^{-1}[P(H_1|H_0)] - d/2$   
 这样有:

$$\begin{aligned} P(H_1|H_1) &= Q(\ln \eta/d - d/2) \\ &= Q[Q^{-1}[P(H_1|H_0)] - d/2 - d/2] = Q[Q^{-1}[P(H_1|H_0)] - d] \end{aligned}$$

这说明, 当给定  $P(H_1|H_0)$  时,  $P(H_1|H_1)$  随功率信噪比 ( $d^2 = NA^2/\sigma^2$ ) 单调增加。


另一方面, 采样次数  $N \uparrow \Rightarrow d \uparrow, p(l|H_0), p(l|H_1)$  的间距  $d \uparrow$ , 检测性能  $\uparrow$ 。

$N$  次独立采样, 样本为

$$n_i \sim \mathcal{N}(\mathbf{0}, \sigma^2)$$

$$H_0 : x_i = n_i \quad (l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$$

$$H_1 : x_i = A + n_i \quad (l|H_1) \sim \mathcal{N}(m, \frac{\sigma^2}{N})$$



$p(l|H_j)(j=0,1)$ : 假设  $H_j$  下观测信号的概率密度函数;  $r^+ = \frac{\ln \eta}{d} + \frac{d}{2}$ ;  $\alpha = P(H_1|H_0)$

检验统计量  $l(x)$ :

$$(l|H_0) \sim \mathcal{N}(0, \frac{1}{N}\sigma^2), \quad (l|H_1) \sim \mathcal{N}(A, \frac{1}{N}\sigma^2)$$

归一化后,  $(l|H_j) \sim \mathcal{N}(0, 1)$

判决表达式:

$$I(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma^+$$

判决概率:(其中, 信噪比  $d^2 = \frac{NA^2}{\sigma^2}$ )

$$\begin{aligned} P(H_1|H_0) &= Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right), & P(H_0|H_0) &= 1 - Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right) \\ P(H_1|H_1) &= Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right), & P(H_0|H_1) &= 1 - Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right) \end{aligned}$$

### 性能分析:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$

统计量  $l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i$

$$E[l|H_0] = E\left[\frac{1}{N} \sum_{i=1}^N (x_i|H_0)\right] = E\left[\frac{1}{N} \sum_{i=1}^N n_i\right] = \frac{1}{N} \sum_{i=1}^N E[n_i] = 0$$

$$Var[l|H_0] = E[(l|H_0 - E(l|H_0))^2] = E\left[\left(\frac{1}{N}\sum_{i=1}^N n_i\right)^2\right]$$

$$= \frac{1}{N^2} \sum_{i=1}^N E[n_i^2] = \frac{1}{N^2} \sum_{i=1}^N \sigma^2 = \frac{\sigma^2}{N}$$

因此,  $(l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$

$$p(l|H_0) = \frac{1}{\sqrt{2\pi Var[l|H_0]}} \exp \left[ -\frac{(l - E[l|H_0])^2}{2Var[l|H_0]} \right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp \left[ -\frac{Nl^2}{2\sigma^2} \right]$$



### 性能分析:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$

假设  $H_1$  条件下, 统计量  $l(x)$  为高斯分布, 均值和方差分别为

$$\begin{aligned} E[l|H_1] &= E\left[\frac{1}{N}\sum_{i=1}^N(x_i|H_1)\right] = E\left[\frac{1}{N}\sum_{i=1}^N(A+n_i)\right] = A + \frac{1}{N}\sum_{i=1}^N E[n_i] = A \\ \text{Var}[l|H_1] &= E[(l|H_1 - E(l|H_1))^2] = E\left[\left(\frac{1}{N}\sum_{i=1}^N(A+n_i) - A\right)^2\right] \\ &= \frac{1}{N^2}\sum_{i=1}^N E[n_i^2] = \frac{1}{N^2}\sum_{i=1}^N \sigma^2 = \frac{\sigma^2}{N} \end{aligned}$$

因此,  $(l|H_1) \sim \mathcal{N}(A, \frac{\sigma^2}{N})$

$$p(l|H_1) = \frac{1}{\sqrt{2\pi Var[l|H_1]}} \exp \left[ -\frac{(l - E[l|H_1])^2}{2Var[l|H_1]} \right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp \left[ -\frac{N(l - A)^2}{2\sigma^2} \right]$$

## 18 / 54

## 19 / 54

检验统计量:

$$l(x) = \frac{1}{N} \sum_{i=1}^N (a + bn_i), i = 1, 2, \dots, N$$

其中:  $n_i \sim \mathcal{N}(0, \sigma_n^2)$ , 即  $E[n_i] = 0, Var[n_i] = E[(n_i - E[n_i])^2] = E[n_i^2] = \sigma_n^2$

统计量  $l(x)$  是高斯随机变量  $n_i$  的线性组合, 服从高斯分布, 均值和方差分别为

$$\begin{aligned} E[l] &= E\left[\frac{1}{N}\sum_{i=1}^N(a+bn_i)\right] = \frac{1}{N}\sum_{i=1}^N E[a+bn_i] \\ &= a + \frac{b}{N}\sum_{i=1}^N E[n_i] = a \quad \text{by } E[n_i] = 0 \end{aligned}$$

$$\begin{aligned} \text{Var}[l] &= E[(l - E(l))^2] = E \left[ \left( \frac{1}{N} \sum_{i=1}^N (a + bn_i) - a \right)^2 \right] \\ &= E \left[ \left( \frac{1}{N} \sum_{i=1}^N (bn_i) \right)^2 \right] = E \left[ \left( \frac{b}{N} \sum_{i=1}^N n_i \right)^2 \right] \\ &= \left( \frac{b}{N} \right)^2 \sum_{i=1}^N E[n_i^2] = \left( \frac{b}{N} \right)^2 N \sigma_n^2 = \frac{b^2 \sigma_n^2}{N} \quad \text{by } E[n_i^2] = \sigma_n^2 \end{aligned}$$

检验统计量:

$$l(x) = \frac{1}{N} \sum_{i=1}^N (m + n_i), i = 1, 2, \dots, N$$

$$E[n_i] = 0, Var[n_i] = E[(n_i - E[n_i])^2] = E[n_i^2] = \sigma_n^2$$

统计量  $l(x)$  是高斯随机变量  $n_i$  的线性组合, 服从高斯分布, 均值和方差分别为

$$\begin{aligned} E[l] &= E\left[\frac{1}{N}\sum_{i=1}^N(m+n_i)\right] = \frac{1}{N}\sum_{i=1}^N E[m+n_i] \\ &= m + \frac{1}{N}\sum_{i=1}^N E[n_i] \quad \text{by } E[n_i] = 0 \end{aligned}$$

$$= m$$

$$\begin{aligned} Var[l] &= E[(l - E(l))^2] = E \left[ \left( \frac{1}{N} \sum_{i=1}^N (m + n_i) - m \right)^2 \right] \\ &= E \left[ \left( \frac{1}{N} \sum_{i=1}^N n_i \right)^2 \right] = E \left[ \left( \frac{1}{N} \sum_{i=1}^N n_i \right)^2 \right] \\ &= \frac{1}{N^2} \sum_{i=1}^N E[n_i^2] = \frac{1}{N^2} N \sigma_n^2 && \text{by } E[n_i^2] = \sigma_n^2 \\ &= \frac{\sigma_n^2}{N} \end{aligned}$$

### 准备知识

### 准备知识

### 准备知识

### 准备知识

### 准备知识

### 准备知识



### 准备知识

### 准备知识

### 准备知识

又因为检测判决门限  $\gamma = \frac{A}{2}$ , 所以两种错误判决概率分别为

$$\begin{aligned} P(H_1|H_0) &= \int_{\gamma}^{\infty} p(l|H_0)dl = \int_{\frac{A}{2}}^{\infty} \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left(-\frac{l^2}{2\sigma^2}\right) dl \\ &\stackrel{l=\sigma u}{=} \int_{\frac{A}{2\sigma}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\ &= Q\left[\frac{A}{2\sigma}\right] = Q\left[\frac{d}{2}\right] \quad \text{by } d^2 \stackrel{\text{def}}{=} A^2/\sigma^2 \end{aligned}$$


$$Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} \exp(-\frac{u^2}{2}) du.$$

$Q(x)$  是单调递减函数, 其反函数:  $Q^{-1}[\bullet]$

## 准备知识

## 准备知识





## ex5 推导 (4)



两种错误判决概率:

$$P(H_1|H_0) = Q[\frac{d}{2}], \quad P(H_0|H_1) = Q[\frac{d}{2}]$$

其中,  $d^2 \stackrel{\text{def}}{=} A^2/\sigma^2$ 。所以, 平均错误概率  $P_e$  为

$$\begin{aligned} P_e &= P(H_0)P(H_1|H_0) + P(H_1)P(H_0|H_1) \\ &= \frac{1}{2}Q[\frac{d}{2}] + \frac{1}{2}Q[\frac{d}{2}] = Q[\frac{d}{2}] \end{aligned}$$

$Q(x)$  是单调递减函数, 信噪比  $d$  越高, 平均错误概率越小, 检测性能越好。



$p(l|H_j)(j = 0, 1)$ : 假设  $H_j$  下观测信号的概率

$$Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} \exp(-\frac{u^2}{2}) du.$$

在贝叶斯准则中,当代价因子满足:  $c_{10} - c_{00} = c_{01} - c_{11}$  时

由条件概率公式, 有

当  $dx$  很小时, 有

$$P(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x} | H_1) = p(\mathbf{x} | H_1) d\mathbf{x}, \quad P(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x}) = p(\mathbf{x}) d\mathbf{x}$$

$P(H_1 | (\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})) = P(H_1 | \mathbf{x})$ , 从而得

类似地,可得

$$P(H_0)p(\mathbf{x}|H_0) = p(\mathbf{x})P(H_0|\mathbf{x})$$

# 最大后验概率准则

$$P(H_1)p(\mathbf{x}|H_1) = p(\mathbf{x})P(H_1|\mathbf{x}), \quad P(H_0)p(\mathbf{x}|H_0) = p(\mathbf{x})P(H_0|\mathbf{x})$$

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P(H_0)}{P(H_1)} \implies P(H_1)p(\mathbf{x}|H_1) \underset{H_0}{\overset{H_1}{\geq}} P(H_0)p(\mathbf{x}|H_0)$$

$$p(\mathbf{x})P(H_1|\mathbf{x}) \underset{H_0}{\overset{H_1}{\geq}} p(\mathbf{x})P(H_0|\mathbf{x})$$

$$P(H_1|\mathbf{x}) \underset{H_0}{\overset{H_1}{\geq}} P(H_0|\mathbf{x})$$

$P(H_j|\mathbf{x}) (j = 0, 1)$  表示已经获得观测量  $\mathbf{x}$  的条件下, 假设  $H_j$  为真时的概率, 称为后验概率。

按照最小平平均代价的贝叶斯准则在代价因子满足:  $c_{10} - c_{00} = c_{01} - c_{11}$  时, 就成为最大后验概率准则 (**maximum a posteriori probability criterion**)





假设  $H_j$  为真, 判决所付出的平均代价为:

$$C(H_j) = \sum_{i=0}^1 c_{ij} P(H_i | H_j)$$

$$C(H_0) = c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)$$
$$C(H_1) = c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)$$
$$C = P(H_0)C(H_0) + P(H_1)C(H_1)$$

# 平均代价 $C(P_1)$ 是先验概率 $P_1$ 的严格上凸函数



$$\eta \stackrel{\text{def}}{=} \eta(P_1) = \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} = \frac{(1 - P_1)(c_{10} - c_{00})}{P_1(c_{01} - c_{11})} = \frac{1}{P_1(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$

$$\text{先验概率 } P_1 \stackrel{\text{def}}{=} P(H_1), \quad P_F \stackrel{\text{def}}{=} P_F(P_1) = P(H_1|H_0), \quad P_M \stackrel{\text{def}}{=} P_M(P_1) = P(H_0|H_1)$$

$$P(H_0|H_0) = 1 - P(H_1|H_0) = 1 - P_F(P_1), \quad P(H_1|H_1) = 1 - P(H_0|H_1) = 1 - P_M(P_1)$$

$$C(P_1) = c_{00} + (c_{10} - c_{00})P_F(P_1) + \quad \text{平均代价 } C(P_1) \text{ 是先验概率 } P_1 \text{ 的严格上凸函数}$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)]$$

$$P_1 \uparrow \implies \eta \downarrow, P_M \downarrow, P_F \uparrow, P_D \uparrow, C \uparrow \sim C_{\min\max} \sim \downarrow$$

# 直线 $C(P_1, P_{1g})$ 与上凸函数 $C(P_1)$

**目的:** 尽可能避免产生过分大的代价,使极大可能代价最小化。

- ① 猜测一个先验概率  $P_{1g}$ , 以  $\eta(P_{1g})$  为门限进行判决。
- ②  $P_{1g}$  确定,  $P_M(P_{1g})$  和  $P_F(P_{1g})$  即可确定。
- ③  $P_{1g}$  确定, 则  $C(P_1, P_{1g})$  表示与上凸函数曲线  $C(P_1)$  的切线, 如图中的直线  $b$ ,  $c$ 。


$$\eta = \eta(P_{1g}) = \frac{1}{P_{1g}(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$

$$C(P_1) = c_{00} + (c_{10} - c_{00})P_F(P_1) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)]$$

$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$




# 极小极大化准则

**目的:** 尽可能避免产生过分大的代价,使极大可能代价最小化。

- ④ 如果实际  $P_1 = P_{1g}$ , 平均代价最小, 在直线  $b$  与  $C(P_1)$  的切点处,  $C(P_1 = P_{1g}, P(1_g))$ 。
- ⑤ 如果实际  $P_1 \neq P_{1g}$ , 比如  $P_1 = P_{11}$ , 则平均代价远大于  $C(P_1 = P_{1g}, P(1_g))$ , 在直线  $P_1 = P_{11}$  与直线  $b$  的交点处。
- ⑥ 如果猜测的先验概率为  $P_{1g}^*$ , 则无论实际的先验概率  $P_1$  为多大, 平均代价都等于  $C_{minmax}$ , 而不会产生过分大的代价。产生的代价与先验概率  $P_1$  无关。  
 $P_{1g}^*$  即是先验概率  $P_1$  最理想的猜测值。

$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) + P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$





## ex6


$$\begin{aligned}
 P_e &= P(H_1)P(H_0|H_1) + P(H_0)P(H_1|H_0) \\
 &= P(H_1)P_M + P(H_0)P_F \\
 &= [P(H_1) + P(H_0)]P_F \\
 &= P_F = P(H_1|H_0) \\
 &= Q\left(\frac{\gamma}{\sigma}\right) = Q\left(\frac{A}{2\sigma}\right) \\
 &= Q\left(\frac{d}{2}\right)
 \end{aligned}$$

$$\text{by } P_M(P_{1g}^*) = P_F(P_{1g}^*)$$

$$\text{by } P(H_1) + P(H_0) = 1, P_F \stackrel{\text{def}}{=} P(H_1|H_0)$$

$$\text{by } \gamma = \frac{A}{2}$$

$$\text{by 功率信噪比 } d^2 = \frac{A^2}{\sigma^2}$$




错误判决概率 (虚警概率)  $P_F \stackrel{\text{def}}{=} P(H_1|H_0)$  **尽可能小**, 正确判决概率 (检测概率)  $P_D \stackrel{\text{def}}{=} P(H_1|H_1)$  **尽可能大**。

漏警概率  $P(H_0|H_1)$  + 检测概率  $P(H_1|H_1) = 1$ , 虚警概率  $P(H_1|H_0) = \alpha$

当  $J$  最小  $\implies$  漏警概率 ( $P(H_0|H_1)$ ) 最小  $\implies$  检测概率 ( $P(H_1|H_1)$ ) 最大。

# 奈曼皮尔逊准则

- ① 图中, 三个判决域 ( $R_{0i}, R_{1i}$ ) 均满足错误判决概率  
 $P_i(H_1|H_0) = \alpha (i = 0, 1, 2)$ 。
- ② 原则上判决域  $R_0$  和  $R_1$  有无限多种划分方法, 均可以保证错误判决概率  $P(H_1|H_0) = \alpha$ , 但是正确判决概率  $P(H_1|H_1)$  一般是不一样的。
- ③ 至少有一种判决域划分能使  
 $P(H_1|H_0) = \alpha$ , 又能使  $P(H_1|H_1)$  到达最大。



奈曼-皮尔逊检测准则是一定存在的

## ex3-7

## 步骤 4: 计算判决门限

$$x \underset{H_0}{\overset{H_1}{\geq}} \sigma^2 \ln \mu + \frac{1}{2} \stackrel{\text{def}}{=} \gamma$$


在错误判决概率 (虚警概率)  $P_F \stackrel{\text{def}}{=} P(H_1|H_0) = 0.1$  条件下确定判决门限

$$P_F \stackrel{\text{def}}{=} P(H_1|H_0) = \int_{\gamma}^{\infty} p(x|H_0) dx = \int_{\gamma}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = Q(\gamma) = 0.1$$

解得:  $\gamma = 1.29, \mu = 2.2$

正确判决概率 (检测概率):

$$\begin{aligned} P(H_1|H_1) &= \int_{\gamma}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x-1)^2}{2}\right] dx \\ &= \int_{1.29}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x-1)^2}{2}\right] dx = 0.386 \end{aligned}$$



判决域及判决概念率  $P(H_1|H_0)$  和  $P(H_1|H_1)$

检测模型:

$$H_0: x = n$$


$$H_1: x = A + n$$

似然比检验的判别式:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$

统计量  $l(x)$ :

$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i$$



判决域及判决概念率  $P(H_1|H_0)$  和  $P(H_1|H_1)$

错误判别概率 (虚警概率):

$$P_F = P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

正确判别概率 (检测概率):

$$P_D = P(H_1|H_1) = Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

式中  $d^2 = \frac{NA^2}{\sigma^2}$ , 是功率信噪比,  
 $d = \sqrt{NA}/\sigma$ , 称为幅度信噪比。



- $$\lambda(x) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

- $$P_F = P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

- $$P_D = P(H_1|H_1) = Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

- 似然比函数  $\lambda(x)$  超过无穷大门限  $\eta = +\infty$  是不可能事件,  $(P_D, P_F) = (0, 0)$

- 当  $\lambda(x)$  是连续随机变量时,  $\eta \uparrow \implies (P_D, P_F) \downarrow$



信噪比  $d$  是接收机的主要指标之一, 因此常把接收机工作特性改成  $P_D \sim d$  曲线, 而以  $P_F$  作为参变量。


$$P_F = P(H_1|H_0) = Q(\ln \eta/d + d/2)$$

$$\ln \eta/d = Q^{-1}[P(H_1|H_0)] - d/2$$

$$P_D = P(H_1|H_1) = Q(\ln \eta/d - d/2)$$

$$= Q[Q^{-1}[P(H_1|H_0)] - d/2 - d/2]$$

$$= Q[Q^{-1}[P(H_1|H_0)] - d]$$



检测概率  $P_D$  与信噪比  $d$  的关系

$Q(x)$  是递减函数, 当给定  $P_F$  时,  $P_D$  随功率信噪比 ( $d^2 = NA^2/\sigma^2$ ) 单调增加。

$$P_D = P(H_1|H_1) = \int_{\eta}^{\infty} p(\lambda|H_1)d\lambda \stackrel{\text{def}}{=} P_D(\eta)$$

$$P_F = P(H_1|H_0) = \int_{\eta}^{\infty} p(\lambda|H_0)d\lambda \stackrel{\text{def}}{=} P_F(\eta)$$

$$\frac{dP_D(\eta)}{d\eta} = -p(\eta|H_1)$$

$$\frac{dP_F(\eta)}{d\eta} = -p(\eta|H_0)$$

$$\text{by } \Phi'(x) = \frac{d}{dx} \int_a^x f(t)dt = f(x) \quad (a \leq x \leq b)$$

$$\frac{dP_D(\eta)}{dP_F(\eta)} = \frac{-p(\eta|H_1)}{-p(\eta|H_0)} = \frac{p(\eta|H_1)}{p(\eta|H_0)}$$



$$\begin{aligned}
P_D(\eta) &= P[(\lambda|H_1) \geq \eta] \\
&= \int_{\eta}^{\infty} p(\lambda|H_1) d\lambda \\
&= \int_{R_1}^{\infty} p(x|H_1) dx \\
&= \int_{R_1}^{\infty} \lambda p(x|H_0) dx \quad \text{by } \lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \eta \\
&= \int_{\eta}^{\infty} \lambda p(\lambda|H_0) d\lambda \\
&\text{by } \Phi'(x) = \frac{d}{dx} \int_a^x f(t) dt = f(x) \quad (a \leq x \leq b)
\end{aligned}$$

$$\begin{aligned}
\frac{dP_D(\eta)}{d\eta} &= -\eta p(\eta|H_0) \\
\frac{dP_D(\eta)}{dP_F(\eta)} &= \frac{-p(\eta|H_1)}{-p(\eta|H_0)} = \frac{-\eta p(\eta|H_0)}{-p(\eta|H_0)} = \eta
\end{aligned}$$

$$P_D \stackrel{\text{def}}{=} P_F(P_1) = P(H_1|H_1)$$

$$P_F \stackrel{\text{def}}{=} P_F(P_1) = P(H_1|H_0)$$

$$P_M \stackrel{\text{def}}{=} P_M(P_1) = P(H_0|H_1)$$

$$= 1 - P_D$$

$$P_M(P_{1g}^*) = 1 - P_D(P_{1g}^*)$$

$H_1$  含随机变量  $m$  的似然比检验的判别式:

$$\lambda(x) = \frac{p(x|m; H_1)}{p(x|H_0)} = \frac{\int_{-\infty}^{\infty} p(x|m, H_1)p(m)dm}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \eta$$

$p(m)$  未知

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right)$$

$$p(x|m; H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-m)^2}{2\sigma_n^2}\right)$$

$$\lambda(x) = \frac{p(x|m; H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

$$\exp\left(\frac{2mx}{2\sigma_n^2} - \frac{m^2}{2\sigma_n^2}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

$$mx \underset{H_0}{\overset{H_1}{\gtrless}} \sigma_n^2 \ln \eta + \frac{m^2}{2}$$

$$m_0 \leq m \leq m_1, m_0 > 0$$

$$mx \underset{H_0}{\overset{H_1}{\geq}} \sigma_n^2 \ln \eta + \frac{m^2}{2}$$

$$l(x) = x \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma_n^2}{m} \ln \eta + \frac{m}{2} \stackrel{def}{=} \gamma^+$$

$$\int_{\gamma^+}^{\infty} \left( \frac{1}{2\pi\sigma_n^2} \right)^{1/2} \exp\left(-\frac{l^2}{2\sigma_n^2}\right) dl = \alpha$$

$$m_0 \leq m \leq m_1, m_1 < 0$$

$$mx \underset{H_0}{\overset{H_1}{\gtrless}} \sigma_n^2 \ln \eta + \frac{m^2}{2}$$

$$l(x) = x \underset{H_0}{\overset{H_1}{\gtrless}} - \frac{\sigma_n^2}{|m|} \ln \eta - \frac{|m|}{2} \stackrel{\text{def}}{=} \gamma^-$$

$$\int_{-\infty}^{\gamma^-} \left( \frac{1}{2\pi\sigma_n^2} \right)^{1/2} \exp\left(-\frac{l^2}{2\sigma_n^2}\right) dl = \alpha$$

若  $m_0 > 0$ ,  $m$  仅取正值, 则在  $P(H_1|H_0) = \alpha$  的约束下,  $P^{(m)}(H_1|H_1)$  是最大的, 其一致最大功效检验成立;

若  $m_1 < 0$ ,  $m$  仅取负值, 则在  $P(H_1|H_0) = \alpha$  的约束下,  $P^{(m)}(H_1|H_1)$  也是最大的。

若  $m_0 < 0, m_1 > 0$ , 即  $m$  取值可能为正或可能为负的情况下, 无论参量信号的统计检测, 按  $m$  仅取正值设计, 还是按  $m$  仅取负值设计, 都有可能在某些  $m$  值下,  $P^{(m)}(H_1|H_1)$  不满足最大的要求。

例如, 按  $m$  取正设计信号检测系统, 当  $m$  为正时,  $P^{(m)}(H_1|H_1)$  最大, 但当  $m$  为负时,  $P^{(m)}(H_1|H_1)$  可能最小。

因此, 这种情况下不能采用奈曼-皮尔逊准则来实际最佳检测系统。



若  $m_0 < 0, m_1 > 0$ , 即  $m$  取值可能为正或可能为负, 奈曼-皮尔逊准则不能保证  $P^{(m)}(H_1|H_1)$  最大要求。考虑把约束条件  $P(H_1|H_0) = \alpha$  分成两个  $\alpha/2$ , 假设  $H_1$  的判决域由两部分组成。判决表示式为

$$|x| \underset{H_0}{\overset{H_1}{\geq}} \gamma$$

虽然双边检验比均值  $m$  假定为正确时的单边检验性能差, 但是比均值  $m$  假定为错误时的单边检验性能要好的多。因此不失为一种好的折中方法。



## 51 / 54

$$p(x|H_1) = \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left[-\frac{(x-A)^2}{2\sigma^2}\right]$$

- 



欢迎批评指正！