信号检测与估值

段江涛 机电工程学院



2019年8月

主要内容

- 1 准备知识
- ② 统计检测基本模型

Theorem

如果函数f(x) 在区间 [a,b] 上连续,则积分上限函数

$$\Phi(x) = \int_{a}^{x} f(t)dt$$

在 [a,b] 上具有导数,并且它的导数是

$$\Phi'(x) = \frac{d}{dx} \int_{a}^{x} f(t)dt = f(x) \qquad (a \le x \le b)$$

Theorem

如果函数 f(x) 在区间 [a,b] 上连续,则函数

$$\Phi(x) = \int_{a}^{x} f(t)dt$$

就是 f(x) 在 [a,b] 上的一个原函数。

Theorem

如果函数 F(x) 是连续函数 f(x) 在区间 [a,b] 上的一个原函数,则

$$\int_{a}^{b} f(x)dx = F(b) - F(a)$$

术语(1)

 $H_i(j=0,1)$: 信源输出的信号, 称为假设 H_i

 $P(H_i)(i=0)$: 假设 H_i 为真的先验概率 (先验: 先于试验)

 $(x|H_i)(j=0,1)$: 假设 H_i 下的观测信号是随机变量

 $p(x|H_i)(j=0,1)$: 假设 H_i 下观测信号的概率密度函数

 $(H_i|H_i)(i,j=0,1)$: 在假设 H_i 为真的条件下,判决假设 H_i 成立的结果。

 $P(H_i|H_i)(i,j=0,1)$: 在假设 H_i 为真的条件下,判决假设 H_i 成立的概率。

 c_{ii} : 在假设 H_i 为真的条件下,判决假设 H_i 成立所付出的代价。

贝叶斯判决准则

判决表达式

$$\lambda(x) \underset{H_0}{\overset{H_1}{\geq}} \eta$$

$$\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)}$$

定义为似然比函数

$$\eta \stackrel{def}{=} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})}$$

定义为判决门限

化简 (例如对数似然比检验)

$$\ln \lambda(x) \mathop{\gtrless}_{H_0}^{H_1} \ln \eta$$

M 元信号检测模型

$$\mathbf{R} = \bigcup_{i=0}^{M-1} R_i, \quad R_i \cap R_j = \emptyset, (i \neq j)$$

最佳信号检测 \leftarrow 正确划分观测空间 R 中的各个判决域 $R_i \leftarrow$ 最佳检测准则

两种假设先验等概
$$\Longrightarrow P(H_0) = P(H_1) = \frac{1}{2}$$

采样样本 $\mathbf{x}_i(i=1,2,\ldots,N)$ 之间相互统计独立, 因此其 N 维联合概率密度能够表示成各自一维概率密度之积的形式, 即

$$p(x_1, x_2, \dots, x_N) = p(x_1)p(x_2) \cdots p(x_N) = \prod_{i=1}^{N} p(x_i)$$

思考

如果 n 是均值为零的, 方差为 σ_n^2 的高斯随机变量, 两个假设下的观测信号模型

$$H_1: r = 1 + n$$

$$H_0: r = -1 + n$$

观测信号 $p(r|H_1), p(r|H_0)$ 应服从何种分布?

因为高斯随机变量的特点:高斯随机变量的线性组合还是高斯随机变量。

习题 2.7:
$$x \sim \mathcal{N}(\mu_x, \sigma_x^2)$$
, 则 $(y = ax + b) \sim \mathcal{N}(a\mu_x + b, a^2\sigma_x^2)$ 。

所以,
$$p(r|H_1) \sim \mathcal{N}(1, \sigma_n^2)$$
, $p(r|H_0) \sim \mathcal{N}(-1, \sigma_n^2)$


直接计算:
$$E(r|H_0) = E(1+n) = 1 + E(n) = 1$$
, $Var(r|H_0) = E[(r|H_0 - E(r|H_0))^2] = E[n^2] = \sigma_n^2 \implies r|H_0 \sim \mathcal{N}(1, \sigma_n^2)$
 $E(r|H_1) = E(-1+n) = -1 + E(n) = -1$, $Var(r|H_1) = E[(r|H_1 - E(r|H_1))^2] = E[n^2] = \sigma_n^2 \implies r|H_1 \sim \mathcal{N}(-1, \sigma_n^2)$

$$n \sim \mathcal{N}(0, \sigma^2)$$

$$H_0: x = n$$
 $x \sim \mathcal{N}(0, \sigma^2)$

$$H_1: x = m + n \quad x \sim \mathcal{N}(m, \sigma^2)$$

判决表达式:
$$x \underset{H_0}{\gtrless} \frac{\sigma^2}{m} \ln \eta + \frac{m}{2}$$





 $p(l|H_j)(j=0,1)$: 假设 H_j 下观测信号的概率 密度函数; $r^+ = \frac{\sigma^2}{m} \ln \eta + \frac{m}{2}$; $\alpha = P(H_1|H_0)$

思考

- **①** $\frac{m}{2}$ 是两个假设的中间值, $\frac{\sigma^2}{m} \ln \eta$ 为中间值的修正量, 其含义如何?
- ② 考虑 m > 0, m < 0, m = 0 时, 如何构造判决表达式?

- ① m = 0 时: H_0, H_1 成为一样的信号。
- ② $m \uparrow \Longrightarrow$ 中间值修正量 $(\frac{\sigma^2}{m} \ln \eta) \downarrow$, r 越接近于中间值 $\frac{m}{2}$.
- 3 m 值越大, 更易区分两种假设, 检测性能越好。





经过上述化简,信号检测的判决式由似然比检验的形式,简化为检验统计量 l(x) 与检测门限 γ 相比较的形式,形成贝叶斯检测基本基本表达式:

$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^{N} x_i \underset{H_0}{\gtrless} \frac{\sigma^2 \ln \eta}{Nm} + \frac{m}{2} \stackrel{\text{def}}{=} \gamma^+$$


检验统计量 $l(x) \stackrel{def}{=} \frac{1}{N} \sum_{i=1}^{N} x_i$ 是观测信号 $x_i (i = 1, 2, ..., N)$ 的求和取平均值的结果,即它是 $x_i (i = 1, 2, ..., N)$ 的函数,是一个随机变量。

而无论是在假设 H_0 下,还是在假设 H_1 下, $(x_i|H_0)$, $(x_i|H_1)$ 均服从高斯分布,因为高斯随机变量的线性组合还是高斯随机变量,所以两种假设下的观测量 $(l|H_0)$, $(l|H_1)$ 也是服从高斯分布的随机变量。

N次独立采样,样本为

 $x_i (i = 1, 2, ..., N)$

$$n_i \sim \mathcal{N}(0, \sigma^2)$$
 $H_0: x_i = n_i$ $(l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$
 $H_1: x_i = m + n_i$ $(l|H_1) \sim \mathcal{N}(m, \frac{\sigma^2}{N})$




 $p(l|H_j)(j=0,1)$: 假设 H_j 下观测信号的概率 密度函数; $r^+ = \frac{\sigma^2 \ln \eta}{Nm} + \frac{m}{2}$; $\alpha = P(H_1|H_0)$

$$(\mathbf{x}|H_0) \sim \mathcal{N}(0, \sigma^2), \quad (\mathbf{x}|H_1) \sim \mathcal{N}(A, \sigma^2)$$

检验统计量 l(x):

$$(l|H_0) \sim \mathcal{N}(0, \frac{1}{N}\sigma^2), \quad (l|H_1) \sim \mathcal{N}(A, \frac{1}{N}\sigma^2)$$

归一化后, $(l|H_j) \sim \mathcal{N}(0, 1)$



 $p(l|H_j)(j=0,1)$: 假设 H_j 下观测信号的概率 密度函数; $r^+ = \frac{\ln \eta}{d} + \frac{d}{2}$; $\alpha = P(H_1|H_0)$

判决表达式:


$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^{N} x_i \underset{H_0}{\gtrless} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma^+$$

判决概率:(其中,信噪比 $d^2 = \frac{NA^2}{\sigma^2}$)


$$P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right), \qquad P(H_0|H_0) = 1 - Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

$$P(H_1|H_1) = Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right), \qquad P(H_0|H_1) = 1 - Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

贝叶斯检测性能分析小结 (ex3 小结 2)



 $p(l|H_j)(j=0,1)$: 假设 H_j 下观测信号的概率 密度函数; $r^+ = \frac{\ln \eta}{d} + \frac{d}{2}$; $\alpha = P(H_1|H_0)$



$$Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} \exp(-\frac{u^2}{2}) du.$$
 $Q(x)$ 是单调递减函数, 其反函数: $Q^{-1}[ullet]$

13/44

因为 $P(H_1|H_0) = Q(\ln \eta/d + d/2) \implies \ln \eta/d = Q^{-1}[P(H_1|H_0)] - d/2$ 这样有:

$$P(H_1|H_1) = Q(\ln \eta/d - d/2)$$

= $Q[Q^{-1}[P(H_1|H_0)] - d/2 - d/2] = Q[Q^{-1}[P(H_1|H_0)] - d]$

这说明, 当给定 $P(H_1|H_0)$ 时, $P(H_1|H_1)$ 随功率信噪比 $(d^2 = NA^2/\sigma^2)$ 单调增加。 另一方面, 采样次数 $N \uparrow \Longrightarrow d \uparrow, p(l|H_0), p(l|H_1)$ 的间距 $d \uparrow$, 检测性能 \uparrow 。

ex3 小结(1)

N次独立采样, 样本为

$$x_i (i = 1, 2, ..., N)$$

$$n_i \sim \mathcal{N}(0, \sigma^2)$$

$$H_0: x_i = n_i$$
 $(l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$

$$H_1: x_i = A + n_i \quad (l|H_1) \sim \mathcal{N}(m, \frac{\sigma^2}{N})$$



 $p(l|H_j)(j=0,1)$: 假设 H_j 下观测信号的概率 密度函数; $r^+ = \frac{\ln \eta}{d} + \frac{d}{2}$; $\alpha = P(H_1|H_0)$

检验统计量 l(x):

$$(l|H_0) \sim \mathcal{N}(0, \frac{1}{N}\sigma^2),$$

$$(l|H_1) \sim \mathcal{N}(A, \frac{1}{N}\sigma^2)$$

归一化后,
$$(l|H_j) \sim \mathcal{N}(0,1)$$

判决表达式:

$$l(x) \stackrel{def}{=} \frac{1}{N} \sum_{i=1}^{N} x_i \underset{H_0}{\gtrless} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{def}{=} \gamma^+$$

判决概率:(其中, 信噪比 $d^2 = \frac{M^2}{\sigma^2}$)

$$\begin{split} P(H_1|H_0) &= Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right), \\ P(H_1|H_1) &= Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right), \end{split}$$

$$P(H_0|H_0) = 1 - Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

$$P(H_0|H_1) = 1 - Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

ex3—观测量 $(l|H_0)$

性能分析:

$$\frac{1}{N} \sum_{i=1}^{N} x_i \underset{H_0}{\gtrless} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{def}{=} \gamma$$

统计量 $l(x) \stackrel{def}{=} \frac{1}{N} \sum_{i=1}^{N} x_i$

假设 H₀ 条件下, 统计量 l(x) 为高斯分布, 均值和方差分别为

$$E[l|H_0] = E\left[\frac{1}{N}\sum_{i=1}^{N}(x_i|H_0)\right] = E\left[\frac{1}{N}\sum_{i=1}^{N}n_i\right] = \frac{1}{N}\sum_{i=1}^{N}E[n_i] = 0$$

$$Var[l|H_0] = E\left[(l|H_0 - E(l|H_0))^2\right] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}n_i\right)^2\right]$$

$$= \frac{1}{N^2}\sum_{i=1}^{N}E[n_i^2] = \frac{1}{N^2}\sum_{i=1}^{N}\sigma^2 = \frac{\sigma^2}{N}$$

因此, $(l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$

$$p(l|H_0) = \frac{1}{\sqrt{2\pi Var[l|H_0]}} \exp\left[-\frac{(l - E[l|H_0])^2}{2Var[l|H_0]}\right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{Nl^2}{2\sigma^2}\right]$$

ex3—观测量 $(l|H_1)$

性能分析:

$$\frac{1}{N} \sum_{i=1}^{N} x_i \underset{H_0}{\gtrless} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{def}{=} \gamma$$

统计量 $l(x) \stackrel{def}{=} \frac{1}{N} \sum_{i=1}^{N} x_i$

假设 H1 条件下, 统计量 l(x) 为高斯分布, 均值和方差分别为

$$E[l|H_1] = E\left[\frac{1}{N}\sum_{i=1}^{N}(x_i|H_1)\right] = E\left[\frac{1}{N}\sum_{i=1}^{N}(A+n_i)\right] = A + \frac{1}{N}\sum_{i=1}^{N}E[n_i] = A$$

$$Var[l|H_1] = E\left[(l|H_1 - E(l|H_1))^2\right] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(A+n_i) - A\right)^2\right]$$

$$= \frac{1}{N^2}\sum_{i=1}^{N}E[n_i^2] = \frac{1}{N^2}\sum_{i=1}^{N}\sigma^2 = \frac{\sigma^2}{N}$$

因此,
$$(l|H_1) \sim \mathcal{N}(A, \frac{\sigma^2}{N})$$

$$p(l|H_1) = \frac{1}{\sqrt{2\pi Var[l|H_1]}} \exp\left[-\frac{(l - E[l|H_1])^2}{2Var[l|H_1]}\right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{N(l - A)^2}{2\sigma^2}\right]$$

$ex4-l|H_0$

N 次独立采样,样本为:

$$H_0: x_i = 1 + n_i, i = 1, 2, \dots, N$$

$$H_1: x_i = -1 + n_i, i = 1, 2, \dots, N$$

计算平均代价:

$$\frac{1}{N} \sum_{i=1}^{N} x_i \mathop{\gtrless}\limits_{H_0}^{H_1} \frac{\sigma^2 \ln \eta}{2N} = -\frac{\ln 3}{4N} \mathop{=}\limits_{=}^{def} \gamma$$

统计量 $l(x) \stackrel{def}{=} \frac{1}{N} \sum_{i=1}^{N} x_i$ 假设 H_0 条件下, 统计量 l(x) 为高斯分布, 均值和方差分别为

$$\begin{split} E[l|H_0] &= E\left[\frac{1}{N}\sum_{i=1}^{N}(x_i|H_0)\right] = E\left[\frac{1}{N}\sum_{i=1}^{N}(1+n_i)\right] \\ &= \frac{1}{N}\sum_{i=1}^{N}E[(1+n_i)] = \frac{1}{N}\sum_{i=1}^{N}[E(1)+E(n_i)] = \frac{1}{N}\sum_{i=1}^{N}[1+0] = 1 \\ Var[l|H_0] &= E\left[(l|H_0-E[l|H_0])^2\right] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(1+n_i)-E(l)\right)^2\right] \\ &= E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(1+n_i)-1\right)^2\right] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}n_i\right)^2\right] \\ &= \frac{1}{N^2}\sum_{i=1}^{N}E[n_i^2] = \frac{1}{N^2}\sum_{i=1}^{N}\sigma^2 = \frac{\sigma^2}{N} \end{split}$$

因此,
$$(l|H_0) \sim \mathcal{N}(1, \frac{\sigma^2}{N})$$

$$p(l|H_0) = \frac{1}{\sqrt{2\pi Var[l|H_0]}} \exp\left[-\frac{(l - E[l|H_0])^2}{2Var[l|H_0]}\right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{N(l - 1)^2}{2\sigma^2}\right]$$

$ex4-l|H_1$

N 次独立采样,样本为:

$$H_0 : \mathbf{r}_i = 1 + n_i \ i = 1 \ 2$$
 N

$$H_0: x_i = 1 + n_i, i = 1, 2, \dots, N$$

 $H_1: x_i = -1 + n_i, i = 1, 2, \dots, N$

$$\overline{N} \sum_{i=1}^{N} x_i \underset{H_0}{\leqslant} -$$

计算平均代价:

$$\frac{1}{N} \sum_{i=1}^{N} x_i \underset{H_0}{\gtrless} \frac{\sigma^2 \ln \eta}{2N} = -\frac{\ln 3}{4N} \stackrel{\text{def}}{=} \gamma$$
统计量
$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^{N} x_i$$

假设 H_1 条件下, 统计量 l(x) 为高斯分布, 均值和方差分别为

$$\begin{split} E[l|H_1] &= E\left[\frac{1}{N}\sum_{i=1}^{N}(x_i|H_1)\right] = E\left[\frac{1}{N}\sum_{i=1}^{N}(-1+n_i)\right] \\ &= \frac{1}{N}\sum_{i=1}^{N}E[(1+n_i)] = \frac{1}{N}\sum_{i=1}^{N}[E(-1)+E(n_i)] = \frac{1}{N}\sum_{i=1}^{N}[-1+0] = -1 \\ Var[l|H_1] &= E\left[(l|H_1-E[l|H_1]))^2\right] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(-1+n_i)-E(l)\right)^2\right] \\ &= E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(-1+n_i)+1\right)^2\right] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}n_i\right)^2\right] \\ &= \frac{1}{N^2}\sum_{i=1}^{N}E[n_i^2] = \frac{1}{N^2}\sum_{i=1}^{N}\sigma^2 = \frac{\sigma^2}{N} \end{split}$$

因此,
$$(l|H_1) \sim \mathcal{N}(-1, \frac{\sigma^2}{N})$$

$$p(l|H_1) = \frac{1}{\sqrt{2\pi Var[l|H_1]}} \exp\left[-\frac{(l-E[l|H_1])^2}{2Var[l|H_1]}\right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{N(l+1)^2}{2\sigma^2}\right]$$

公式推导练习(1)

检验统计量:

$$l(x) = \frac{1}{N} \sum_{i=1}^{N} (a + bn_i), i = 1, 2, \dots, N$$

其中:
$$n_i \sim \mathcal{N}(0, \sigma_n^2)$$
, 即 $E[n_i] = 0$, $Var[n_i] = E[(n_i - E[n_i])^2] = E[n_i^2] = \sigma_n^2$

统计量 1(x) 为高斯分布,均值和方差分别为

$$E[I] = E\left[\frac{1}{N}\sum_{i=1}^{N}(a+bn_i)\right] = \frac{1}{N}\sum_{i=1}^{N}E[a+bn_i]$$

= $a + \frac{b}{N}\sum_{i=1}^{N}E[n_i] = a$

$$Var[I] = E[(I - E(I))^{2}] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(a + bn_{i}) - a\right)^{2}\right]$$

$$= E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(bn_i)\right)^2\right] = E\left[\left(\frac{b}{N}\sum_{i=1}^{N}n_i\right)^2\right]$$
$$= \left(\frac{b}{N}\right)^2\sum_{i=1}^{N}E[n_i^2] = \left(\frac{b}{N}\right)N\sigma_n^2 = \frac{b^2\sigma_n^2}{N}$$

by $E[n_i^2] = \sigma_n^2$

by $E[n_i] = 0$

2019年8月

公式推导练习(2)

检验统计量:

$$l(x) = \frac{1}{N} \sum_{i=1}^{N} (m + n_i), i = 1, 2, \dots, N$$

其中: m 是常数, $n_i \sim \mathcal{N}(0, \sigma_n^2)$, 即

$$E[n_i] = 0, Var[n_i] = E[(n_i - E[n_i])^2] = E[n_i^2] = \sigma_n^2$$

统计量 l(x) 为高斯分布,均值和方差分别为

$$E[I] = E\left[\frac{1}{N}\sum_{i=1}^{N}(m+n_i)\right] = \frac{1}{N}\sum_{i=1}^{N}E[m+n_i]$$
$$= m + \frac{1}{N}\sum_{i=1}^{N}E[n_i]$$

= m

$$Var[I] = E[(I - E(I))^{2}] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}(m + n_{i}) - m\right)^{2}\right]$$

$$= E\left[\left(\frac{1}{N}\sum_{i=1}^{N}n_{i}\right)^{2}\right] = E\left[\left(\frac{1}{N}\sum_{i=1}^{N}n_{i}\right)^{2}\right]$$

$$= \frac{1}{N^{2}}\sum_{i=1}^{N}E[n_{i}^{2}] = \frac{1}{N^{2}}N\sigma_{n}^{2}$$

$$= \frac{\sigma_{n}^{2}}{N}$$

by $E[n_i^2] = \sigma_n^2$

by $E[n_i] = 0$

两个假设下, 观测量 x 均服从高斯分布, $(x|H_0) \sim \mathcal{N}(0, \sigma^2)$, $(x|H_1) \sim \mathcal{N}(A, \sigma^2)$.

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$
$$p(x|H_1) = \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left[-\frac{(x-A)^2}{2\sigma^2}\right]$$

两个假设先验概率等概, 且 $c_{00} = c_{11} = 0$, $c_{10} = c_{01} = 1$, 所以似然比检验判别 式为:

$$\lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} = \exp\left(\frac{2Ax - A^2}{2\sigma^2}\right) \underset{H_0}{\overset{H_1}{\geqslant}} \eta = 1$$

化简得判决表达式:

$$x \underset{H_0}{\gtrless} \frac{A}{2}$$

由于检验统计量 l(x) = x,所以

$$\begin{split} p(l|H_0) &= \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left(-\frac{l^2}{2\sigma^2}\right) \\ p(l|H_1) &= \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left[-\frac{(l-A)^2}{2\sigma^2}\right] \end{split}$$


ex5 推导(2)

又因为检测判决门限 $\gamma = \frac{4}{5}$, 所以两种错误判决概率分别为


$$P(H_1|H_0) = \int_{\gamma}^{\infty} p(l|H_0)dl = \int_{\frac{d}{2}}^{\infty} \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left(-\frac{l^2}{2\sigma^2}\right) dl$$

$$\stackrel{l=\sigma u}{=} \int_{\frac{d}{2\sigma}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$= Q\left[\frac{A}{2\sigma}\right] = Q\left[\frac{d}{2}\right] \quad \text{by } d^2 \stackrel{def}{=} A^2/\sigma^2$$



 $p(l|H_j)(j=0,1)$: 假设 H_j 下观测信号的概率 密度函数; $\alpha = P(H_1|H_0)$



$$Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} \exp(-\frac{u^2}{2}) du.$$

$$Q(x) 是 单调递减函数, 其反函数: Q^{-1}[\bullet]$$


ex5 推导(3)


$$P(H_0|H_1) = \int_{-\infty}^{\gamma} p(l|H_1)dl = \int_{-\infty}^{\frac{A}{2}} \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left(-\frac{(l-A)^2}{2\sigma^2}\right) dl$$

$$\stackrel{l=A+\sigma u}{=} \int_{-\infty}^{-\frac{A}{2\sigma}} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$= 1 - \int_{-\frac{A}{2\sigma}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$= 1 - Q[-\frac{A}{2\sigma}] = 1 - Q[-\frac{d}{2}] = Q[\frac{d}{2}] \quad \text{by } d^2 \stackrel{\text{def}}{=} A^2/\sigma^2$$





ex5 推导(4)


两种错误判决概率:

$$P(H_1|H_0) = Q[\frac{d}{2}], \qquad P(H_0|H_1) = Q[\frac{d}{2}]$$


其中, $d^2 \stackrel{def}{=} A^2/\sigma^2$ 。所以, 平均错误概率 P_e 为

$$P_e = P(H_0)P(H_1|H_0) + P(H_1)P(H_0|H_1)$$
$$= \frac{1}{2}Q[\frac{d}{2}] + \frac{1}{2}Q[\frac{d}{2}] = Q[\frac{d}{2}]$$

Q(x) 是单调递减函数,信噪比 d 越高,平均错误概率越小,检测性能越好。



 $p(l|H_j)(j=0,1)$: 假设 H_j 下观测信号的概率



$$Q(x) = \int_{x}^{\infty} \frac{1}{\sqrt{2\pi}} \exp(-\frac{u^2}{2}) du.$$

最大后验概率准则

在贝叶斯准则中, 当代价因子满足: $c_{10}-c_{00}=c_{01}-c_{11}$ 时

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\geqslant}} \frac{P(H_0)}{P(H_1)} \implies P(H_1)p(\mathbf{x}|H_1) \underset{H_0}{\overset{H_1}{\geqslant}} P(H_0)p(\mathbf{x}|H_0)$$

由条件概率公式,有

$$P(H_1|(x \le X \le x + dx)) = \frac{P((x \le X \le x + dx)|H_1)P(H_1)}{P(x \le X \le x + dx)}$$

当 dx 很小时,有

$$P((\mathbf{x} \le X \le \mathbf{x} + d\mathbf{x})|H_1) = p(\mathbf{x}|H_1)d\mathbf{x}, \quad P(\mathbf{x} \le X \le \mathbf{x} + d\mathbf{x}) = p(\mathbf{x})d\mathbf{x}$$
 $P(H_1|(\mathbf{x} \le X \le \mathbf{x} + d\mathbf{x})) = P(H_1|\mathbf{x}),$ 从而得
$$p(\mathbf{x}|H_1)d\mathbf{x}P(H_1) = p(\mathbf{x}|H_1)P(H_1)$$

$$P(H_1|\mathbf{x}) = \frac{p(\mathbf{x}|H_1)d\mathbf{x}P(H_1)}{p(\mathbf{x})d\mathbf{x}} = \frac{p(\mathbf{x}|H_1)P(H_1)}{p(\mathbf{x})}$$
$$\implies P(H_1)p(\mathbf{x}|H_1) = p(\mathbf{x})P(H_1|\mathbf{x})$$

类似地,可得

$$P(H_0)p(\mathbf{x}|H_0) = p(\mathbf{x})P(H_0|\mathbf{x})$$

最大后验概率准则

$$P(H_{1})p(\mathbf{x}|H_{1}) = p(\mathbf{x})P(H_{1}|\mathbf{x}), \quad P(H_{0})p(\mathbf{x}|H_{0}) = p(\mathbf{x})P(H_{0}|\mathbf{x})$$

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_{1})}{p(\mathbf{x}|H_{0})} \underset{H_{0}}{\overset{H_{1}}{\geqslant}} \frac{P(H_{0})}{P(H_{1})} \Longrightarrow P(H_{1})p(\mathbf{x}|H_{1}) \underset{H_{0}}{\overset{H_{1}}{\geqslant}} P(H_{0})p(\mathbf{x}|H_{0})$$

$$p(\mathbf{x})P(H_{1}|\mathbf{x}) \underset{H_{0}}{\overset{H_{1}}{\geqslant}} p(\mathbf{x})P(H_{0}|\mathbf{x})$$

$$P(H_{1}|\mathbf{x}) \underset{H_{1}}{\overset{H_{1}}{\geqslant}} P(H_{0}|\mathbf{x})$$

 $P(H_j|\mathbf{x})(j=0,1)$ 表示已经获得观测量 \mathbf{x} 的条件下,假设 H_j 为真时的概率,称为**后验概率**。

按照最小平均代价的贝叶斯准则在代价因子满足: $c_{10} - c_{00} = c_{01} - c_{11}$ 时,就成为最大后验概率准则 (maximum a posteriori probability criterion)

段汀涛 (LSEC,AMSS,CAS) 信号检测与估值 2019 年 8 月

平均代价

假设 H_i 为真, 判决所付出的平均代价为:

$$C(H_j) = \sum_{i=0}^{1} c_{ij} P(H_i|H_j)$$

判决 Ho 成立的代价

$$C(H_0) = c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)$$

判决 H₁ 成立的代价


$$C(H_1) = c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)$$

总代价:

$$C = P(H_0)C(H_0) + P(H_1)C(H_1)$$

段江涛 (LSEC,AMSS,CAS) 信号检测与估值

P_F, P_M, P_D (1)




极小极大化准则

目的: 避免产生过分大的代价, 使极大可能代价极小化。

- lacklet 猜测一个先验概率 P_{1g} , 以 $\eta(P_{1g})$ 为门限进行判决。
- ② P_{1g} 确定, $P_M(P_{1g})$ 和 $P_F(P_{1g})$ 即可确定。
- **3** $C(P_1, P_{1g})$ 是一条与曲线 a 相且的直线 b, 切点在 $C(P_1 = P_{1g})$ 处。
- **④** 如果猜测的先验概率为 P_{1g}^* ,则无论实际的先验概率 P_1 为多大,平均代价都等于 C_{minmax} ,而不会产生过分大的代价。

$$\begin{split} \eta &= \eta(P_{1g}) = \frac{1}{P_{1g}(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}} \\ C(P_{1}, P_{1g}) &= c_{00} + (c_{10} - c_{00})P_{F}(P_{1g}) + \\ P_{1}[(c_{11} - c_{00}) + (c_{01} - c_{11})P_{M}(P_{1g}) - (c_{10} - c_{00})P_{F}(P_{1g})] \end{split}$$



此时,极小化极大代价就是平均错误概率 $P_F(P_{1g})$

似然比检验的判别式:

$$\lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} \stackrel{H_1}{\gtrsim} \eta$$

$$\lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} \stackrel{H_1}{\gtrsim} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} \stackrel{def}{=} \eta$$

$$\eta \stackrel{def}{=} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} = \frac{(1 - P_1)(c_{10} - c_{00})}{P_1(c_{01} - c_{11})} = \frac{1}{P_1(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$
快概率:

判决概率:

$$P_F = P(H_1|H_0) = \int_{\eta}^{\infty} p(\lambda|H_0)d\lambda$$
$$P_D = P(H_1|H_1) = \int_{\eta}^{\infty} p(\lambda|H_1)d\lambda$$

$$\begin{split} P_D &= P_D = P(H_1|H_1) = \int_{\eta}^{\infty} p(\lambda|H_1) d\lambda = P_D(\eta) \\ P_F &= P(H_1|H_0) = \int_{\eta}^{\infty} p(\lambda|H_0) d\lambda = P_F(\eta) \\ \frac{dP_D(\eta)}{d\eta} &= -p(\eta|H_1) \\ \frac{dP_F(\eta)}{d\eta} &= -p(\eta|H_0) \\ \text{by } \Phi'(x) &= \frac{d}{dx} \int_a^x f(t) dt = f(x) \qquad (a \leq x \leq b) \\ \frac{dP_D(\eta)}{dP_F(\eta)} &= \frac{-p(\eta|H_1)}{-p(\eta|H_0)} = \frac{p(\eta|H_1)}{p(\eta|H_0)} \end{split}$$

$$\begin{split} P_D(\eta) &= P[(\lambda|H_1) \geq \eta] \\ &= \int_{\eta}^{\infty} p(\lambda|H_1) d\lambda \\ &= \int_{R_1}^{\infty} p(x|H_1) dx \\ &= \int_{R_1}^{\infty} \lambda p(x|H_0) dx \qquad \text{by } \lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} \mathop{\gtrless}_{H_0}^{H_1} \eta \\ &= \int_{\eta}^{\infty} \lambda p(\lambda|H_0) d\lambda \\ &= \int_{\eta}^{\infty} \lambda p(\lambda|H_0) d\lambda \\ &\frac{dP_D(\eta)}{d\eta} = -\eta p(\eta|H_0) \\ &\frac{dP_D(\eta)}{dP_F(\eta)} = \frac{-p(\eta|H_1)}{-p(\eta|H_0)} = \frac{-\eta p(\eta|H_0)}{-p(\eta|H_0)} = \eta \end{split}$$

 H_1 含随机变量 m 的似然比检验的判别式:

$$\lambda(x) = \frac{p(x|m; H_1)}{p(x|H_0)} = \frac{\int_{-\infty}^{\infty} p(x|m, H_1) p(m) dm}{p(x|H_0)} \mathop{\gtrless}_{H_0}^{H_1} \eta$$

$$p(x|H_0) = (\frac{1}{2\pi\sigma_n^2})^{1/2} \exp(-\frac{x^2}{2\sigma_n^2})$$

$$p(x|m;H_1) = (\frac{1}{2\pi\sigma_n^2})^{1/2} \exp(-\frac{(x-m)^2}{2\sigma_n^2})$$

$$\lambda(x) = \frac{p(x|m;H_1)}{p(x|H_0)} \underset{H_0}{\gtrless} \eta$$

$$\exp(\frac{2mx}{2\sigma_n^2} - \frac{m^2}{2\sigma_n^2}) \underset{H_0}{\gtrless} \eta$$

$$mx \underset{H_0}{\gtrless} \sigma_n^2 \ln \eta + \frac{m^2}{2}$$

$$m_{0} \leq m \leq m_{1}, m_{0} > 0$$

$$mx \underset{H_{0}}{\overset{H_{1}}{\geqslant}} \sigma_{n}^{2} \ln \eta + \frac{m^{2}}{2}$$

$$l(x) = x \underset{H_{0}}{\overset{H_{1}}{\geqslant}} \frac{\sigma_{n}^{2}}{m} \ln \eta + \frac{m}{2} \frac{\text{def}}{=} \gamma^{+}$$

$$\int_{\gamma^{+}}^{\infty} (\frac{1}{2\pi\sigma_{\pi}^{2}})^{1/2} \exp(-\frac{l^{2}}{2\sigma_{\pi}^{2}}) dl = \alpha$$

$$\begin{split} & m_0 \leq m \leq m_1, m_1 < 0 \\ & m x \underset{H_0}{\gtrless} \sigma_n^2 \ln \eta + \frac{m^2}{2} \\ & l(x) = x \underset{H_0}{\leqq} -\frac{\sigma_n^2}{|m|} \ln \eta - \frac{|m|}{2} \underset{=}{\stackrel{def}{=}} \gamma^- \\ & \int_{-\infty}^{\gamma^-} (\frac{1}{2\pi\sigma_n^2})^{1/2} \exp(-\frac{l^2}{2\sigma_n^2}) dl = \alpha \end{split}$$

若 $m_0 > 0$, m 仅取正值, 则在 $P(H_1|H_0) = \alpha$ 的约束下, $P^{(m)}(H_1|H_1)$ 是最大的, 其一致最大功效检验成立;

若 $m_1 < 0$, m 仅取负值, 则在 $P(H_1|H_0) = \alpha$ 的约束下, $P^{(m)}(H_1|H_1)$ 也是最大的。

若 $m_0 < 0, m_1 > 0$,即 m 取值可能为正或可能为负的情况下,无论参量信号的统计检测,按 m 仅取正值设计,还是按 m 仅取负值设计,都有可能在某些 m 值下, $P^{(m)}(H_1|H_1)$ 不满足最大的要求。

例如,按 m 取正设计信号检测系统,当 m 为正时, $P^{(m)}(H_1|H_1)$ 最大,但当 m 为负时, $P^{(m)}(H_1|H_1)$ 可能最小。

因此, 这种情况下不能采用奈曼-皮尔逊准则来实际最佳检测系统。

若 $m_0 < 0, m_1 > 0$,即 m 取值可能为正或可能为负, 奈曼-皮尔逊准则不能保证 $P^{(m)}(H_1|H_1)$ 最大要求。考虑把约束条件 $P(H_1|H_0) = \alpha$ 分成两个 $\alpha/2$,假设 H_1 的 判决域由两部分组成。判决表示式为

$$|x| \mathop{\gtrless}_{H_0}^{H_1} \gamma$$

虽然双边检验比均值 *m* 假定为正确时的单边检验性能差,但是比均值 *m* 假定为错误时的单边检验性能要好的多。因此不失为一种好的折中方法。

广义似然比检验

似然函数

$$p(x|m; H_1) = (\frac{1}{2\pi\sigma_n^2})^{1/2} \exp(-\frac{(x-m)^2}{2\sigma_n^2})$$

对 m 求偏导, 令结果等于零,即

$$\frac{\partial \ln p(x|m; H_1)}{\partial m}|_{m=\widehat{m}_{ml}} = 0$$

解得单次观测时,m 的最大似然估计量 $\hat{m}_{ml} = x$, 于是有

$$p(x|\widehat{m}_{ml}; H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-\widehat{m}_{ml})^2}{2\sigma_n^2}\right)|_{\widehat{m}_{ml}=x} = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2}$$

段江涛 (LSEC,AMSS,CAS)

广义似然比检验

$$p(x|H_0) = (\frac{1}{2\pi\sigma_n^2})^{1/2} \exp(-\frac{x^2}{2\sigma_n^2})$$

$$p(x|\widehat{m}_{ml}; H_1) = (\frac{1}{2\pi\sigma_n^2})^{1/2}$$

代入广义似然比检验中,有

$$\lambda(x) = \frac{p(x|m; H_1)}{p(x|H_0)} \mathop{\gtrless}_{H_0}^{H_1} \eta$$

$$\lambda(x) = \frac{\left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2}}{\left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right)} \mathop{\gtrless}_{H_0}^{H_1} \eta$$

化简得判决表示式

$$x^2 \underset{H_0}{\stackrel{H_1}{\gtrless}} 2\sigma_n^2 \ln \eta \stackrel{\text{def}}{=} \gamma^2 \implies |x| \underset{H_0}{\stackrel{H_1}{\gtrless}} \gamma$$

这正是前面讨论过的双边检验。只是前面是从奈曼-皮尔逊准则出发推导得到。而这里是从似然比检验的概念导出的,似然函数 $p(x|m; H_1)$ 中的信号参量 m 由 其最大似然估计量 \hat{m}_{ml} 代换,所以是广义似然比检验。

$$H_0 = -A + n$$

$$H_1 = A + n$$

$$p(n) = \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left[-\frac{n^2}{2\sigma^2}\right]$$

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left[-\frac{(x+A)^2}{2\sigma^2}\right]$$

$$p(x|H_1) = \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left[-\frac{(x-A)^2}{2\sigma^2}\right]$$

title

- 目标: 正确判决概率 $P(H_i|H_i)$ 尽可能大,错误判决概率 $P(H_i|H_i)(i \neq j)$ 尽可 能小。
- $x_0 \downarrow \Longrightarrow P(H_1|H_1) \uparrow$, $\not \in P(H_0|H_1) \downarrow$, $\not \in MR$ $x_0 \uparrow$, $\not \in RR$ $\not \in RR$
- 因此需要最佳划分判决域

欢迎批评指正!