

# 信号检测与估值

段江涛

机电工程学院



2019 年 9 月

# ch3. 信号检测与估计理论的基础知识

## ch3-3. 派生贝叶斯准则

- 1 最小平均错误概率准则
- 2 最大后验概率准则
- 3 极小极大化准则和奈曼皮尔逊准则
- 4 奈曼—皮尔逊准则

# 派生贝叶斯准则

## 基本要求

- 掌握最小平均错误概率准则和最大后验概率准则
- 理解极小化极大准则和奈曼-皮尔逊准则的应用范围和基本原理

# 最小平均错误概率准则

## 贝叶斯判决准则

$$\frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} \implies \lambda(\mathbf{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

## 最小平均错误概率准则

正确判决不付出代价, 错误判决代价相同。

$$c_{01} = c_{10} = 1, c_{00} = c_{11} = 0$$

# 最小平均错误概率准则—判决域划分

## 最小平均错误概率准则

正确判决不付出代价, 错误判决代价相同。

$$c_{01} = c_{10} = 1, c_{00} = c_{11} = 0$$

$$C(H_0) = c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0) = P(H_1|H_0)$$

$$C(H_1) = c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1) = P(H_0|H_1)$$

最小平均错误概率准则, 平均代价  $C \Leftrightarrow$  平均错误概率  $P_e$

$$C = P(H_0)C(H_0) + P(H_1)C(H_1)$$

$$= P(H_0)P(H_1|H_0) + P(H_1)P(H_0|H_1)$$

# 最小平均错误概率准则—判决域划分


最小平均错误概率准则, 平均代价  $C \Leftrightarrow$  平均错误概率  $P_e$

$$\begin{aligned} C &= P(H_0)C(H_0) + P(H_1)C(H_1) \\ &= P(H_0)P(H_1|H_0) + P(H_1)P(H_0|H_1) \\ &= P(H_0) + \left( \int_{R_0} [P(H_1)p(\mathbf{x}|H_1) - P(H_0)p(\mathbf{x}|H_0)] dx \right) \end{aligned}$$

把被积函数取负值的观测值  $x$  划分给  $R_0$  区域, 而把其余的观测值  $x$  划分给  $R_1$ , 即可保证平均代价最小。

$$P(H_1)p(\mathbf{x}|H_1) < P(H_0)p(\mathbf{x}|H_0)$$

$$P(H_1)p(\mathbf{x}|H_1) \geq P(H_0)p(\mathbf{x}|H_0)$$



$$P(H_1|H_0) = 1 - \int_{R_0} p(x|H_0) dx$$

$$P(H_0|H_1) = \int_{R_0} p(x|H_1) dx$$

判决  $H_0$  假设成立

判决  $H_1$  假设成立

# 最小平均错误概率准则

## 最小平均错误概率准则

$$\frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} < \frac{P(H_0)}{P(H_1)}$$

判决  $H_0$  假设成立

$$\frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \geq \frac{P(H_0)}{P(H_1)}$$

判决  $H_1$  假设成立

⇒

$$\lambda(\mathbf{x}) \stackrel{\text{def}}{=} \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)} \stackrel{\text{def}}{=} \eta$$

⇒

$$\ln \lambda(\mathbf{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \ln \eta$$

⇒

$$l(\mathbf{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \gamma$$

# 最大似然检测准则

## 最小平均错误概率准则

$$\lambda(\mathbf{x}) \stackrel{\text{def}}{=} \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)} \stackrel{\text{def}}{=} \eta$$

## 最大似然检测准则

$c_{00} = c_{11} = 0, c_{01} = c_{10} = 1$ , 且两个假设的先验概率等概, 则最小平均错误准则转化为最大似然检测准则。

$$p(\mathbf{x}|H_1) \underset{H_0}{\overset{H_1}{\gtrless}} p(\mathbf{x}|H_0)$$

先验概率等概的最小平均错误概率准则为最大似然准则 (maximum likelihood criterion)。



# 贝叶斯准则例题 5

在闭启键控通信系统中,两个假设下的观测信号模型为:

$$H_0 : x = n$$

$$H_1 : x = A + n$$

其中, 噪声  $n$  是均值为零, 方差为  $\sigma_n^2$  的高斯噪声, 若两个假设的先验概率相等, 且  $c_{00} = c_{11} = 0, c_{01} = c_{10} = 1$ 。

采用最小平均错误概率准则, 试确定判决表示式, 并求最小平均错误概率。

# 贝叶斯准则例题 5: 解

解: 观测信号模型为:

$$H_0 : x = n$$

$$H_1 : x = A + n$$

由于, 先验概率等概的最小平均错误概率准则就是最大似然准则。因此, 贝叶斯检测判别式为:

$$p(x|H_1) \underset{H_0}{\geq} p(x|H_0) \implies \lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\geq} 1 \stackrel{\text{def}}{=} \eta$$

由于  $n$  是高斯分布随机变量, 因此在  $H_0$  假设下, 检测统计量  $x$  服从高斯分布, 且均值为 0, 方差为  $\sigma_n^2$ ; 在  $H_1$  假设下, 检测统计量  $x$  服从均值为  $A$ , 方差为  $\sigma_n^2$  的高斯分布。

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right) \quad p(x|H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-A)^2}{2\sigma_n^2}\right)$$


$$\lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} = \exp\left(\frac{(x^2 - (x-A)^2)}{2\sigma_n^2}\right) = \exp\left(\frac{A}{\sigma_n^2}x - \frac{A^2}{2\sigma_n^2}\right)$$

# 贝叶斯准则例题 5: 解 (续 1)

$$\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} 1 \stackrel{\text{def}}{=} \eta$$

$$\lambda(x) = \exp\left(\frac{A}{\sigma_n^2}x - \frac{A^2}{2\sigma_n^2}\right)$$

$$x \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma_n^2 \ln \eta}{A} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$



$$P(H_1|H_0) = \int_{\gamma}^{\infty} p(x|H_0)dx \Rightarrow Q(x) = \int_x^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$= \int_{\gamma}^{\infty} \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right) dx$$

by  $x = \sigma_n u$

$$= \int_{\frac{\gamma}{\sigma_n}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

by  $\gamma = \frac{\sigma_n^2 \ln \eta}{A} + \frac{A}{2}$

$$= \int_{\frac{\sigma_n \ln \eta}{A} + \frac{A}{2\sigma_n}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

by  $d^2 = \frac{A^2}{\sigma_n^2}$


$$= Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

# 贝叶斯准则例题 5: 解 (续 2)

$$\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} 1 \stackrel{\text{def}}{=} \eta$$

$$\lambda(x) = \exp\left(\frac{A}{\sigma_n^2}x - \frac{A^2}{2\sigma_n^2}\right)$$

$$x \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma_n^2 \ln \eta}{A} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$



$$P(H_0|H_1) = 1 - \int_{\gamma}^{\infty} p(x|H_1) dx \implies Q(x) = \int_x^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$= 1 - \int_{\gamma}^{\infty} \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-A)^2}{2\sigma_n^2}\right) dx$$

$$\text{by } x = \sigma_n u + A$$

$$= 1 - \int_{\frac{\gamma-A}{\sigma_n}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$\text{by } \gamma = \frac{\sigma_n^2 \ln \eta}{A} + \frac{A}{2}$$

$$= 1 - \int_{\frac{\sigma_n \ln \eta}{A} - \frac{A}{2\sigma_n}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$\text{by } d^2 = \frac{A^2}{\sigma_n^2}$$


$$= 1 - Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

# 贝叶斯准则例题 5: 解 (续 3)

$$\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\geq} 1 \stackrel{\text{def}}{=} \eta \implies \ln \eta = 0$$

$$P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right) = Q\left(\frac{d}{2}\right)$$

$$\begin{aligned} P(H_0|H_1) &= 1 - Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right) \\ &= 1 - Q\left(-\frac{d}{2}\right) = Q\left(\frac{d}{2}\right) \end{aligned}$$



最小平均错误概率准则, 平均代价  $C \Leftrightarrow$  平均错误概率  $P_e$ ,  $P(H_0) = P(H_1) = \frac{1}{2}$


$$\begin{aligned} P_e = C &= P(H_0)P(H_1|H_0) + P(H_1)P(H_0|H_1) \\ &= \frac{1}{2}Q\left(\frac{d}{2}\right) + \frac{1}{2}Q\left(\frac{d}{2}\right) = Q\left(\frac{d}{2}\right) \quad d^2 = \frac{A^2}{\sigma_n^2} \end{aligned}$$

$Q(x)$  是单调递减函数, 信噪比  $d$  越高, 平均错误概率越小, 检测性能越好。

# 标准高斯分布的右尾积分

$$Q(x) = \int_x^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$Q\left(\frac{d}{2}\right) = 1 - Q\left(-\frac{d}{2}\right)$$



# 最大后验概率准则

## 贝叶斯判决准则

$$\frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} \implies \lambda(\mathbf{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

## 最大后验概率准则

代价因子满足:  $c_{10} - c_{00} = c_{01} - c_{11}$

判决表示式

$$\frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$$

## Notes

- 最大后验概率准则形式上与最小平均错误概率准则相同
- 问题: 可写成上述判决表达式形式的, 是否一定可以获得最小平均错误概率?

# 最大后验概率准则不一定能获得最小平均错误概率

## 最大后验概率准则

代价因子满足:  $c_{10} - c_{00} = c_{01} - c_{11}$

判决表示式

$$\frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$$

## Notes

最小平均错误概率准则:  $c_{01} = c_{10} = 1, c_{00} = c_{11} = 0$ 。

可得到最小平均错误概率:

$$P_e = C = P(H_0)C(H_0) + P(H_1)C(H_1) = P(H_0)P(H_1|H_0) + P(H_1)P(H_0|H_1)$$

因此, 虽然最大后验概率准则形式上与最小平均错误概率准则相同。但是不一定能获得最小平均错误概率?



# 最大后验概率准则

在贝叶斯准则中,当代价因子满足:  $c_{10} - c_{00} = c_{01} - c_{11}$  时

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)} \implies P(H_1)p(\mathbf{x}|H_1) \underset{H_0}{\overset{H_1}{\gtrless}} P(H_0)p(\mathbf{x}|H_0)$$

由条件概率公式  $P(A|B) = \frac{P(AB)}{P(B)}$ , 有

$$P(H_1|(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})) = \frac{P((\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})|H_1)P(H_1)}{P(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})}$$

当  $d\mathbf{x}$  很小时, 有  $P(H_1|(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})) = P(H_1|\mathbf{x})$ ,

$$P((\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})|H_1) = p(\mathbf{x}|H_1)d\mathbf{x}, \quad P(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x}) = p(\mathbf{x})d\mathbf{x}$$

从而得

$$\begin{aligned} P(H_1|\mathbf{x}) &= \frac{p(\mathbf{x}|H_1)d\mathbf{x}P(H_1)}{p(\mathbf{x})d\mathbf{x}} = \frac{p(\mathbf{x}|H_1)P(H_1)}{p(\mathbf{x})} \\ \implies P(H_1)p(\mathbf{x}|H_1) &= p(\mathbf{x})P(H_1|\mathbf{x}) \end{aligned}$$

类似地,可得

$$P(H_0)p(\mathbf{x}|H_0) = p(\mathbf{x})P(H_0|\mathbf{x})$$

# 最大后验概率准则

$$P(H_1)p(\mathbf{x}|H_1) = p(\mathbf{x})P(H_1|\mathbf{x}), \quad P(H_0)p(\mathbf{x}|H_0) = p(\mathbf{x})P(H_0|\mathbf{x})$$

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P(H_0)}{P(H_1)} \implies P(H_1)p(\mathbf{x}|H_1) \underset{H_0}{\overset{H_1}{\geq}} P(H_0)p(\mathbf{x}|H_0)$$

$$p(\mathbf{x})P(H_1|\mathbf{x}) \underset{H_0}{\overset{H_1}{\geq}} p(\mathbf{x})P(H_0|\mathbf{x})$$

$$P(H_1|\mathbf{x}) \underset{H_0}{\overset{H_1}{\geq}} P(H_0|\mathbf{x})$$

$P(H_j|\mathbf{x}) (j = 0, 1)$  表示已经获得观测量  $\mathbf{x}$  的条件下, 假设  $H_j$  为真时的概率, 称为后验概率。

按照最小平均代价的贝叶斯准则在代价因子满足:  $c_{10} - c_{00} = c_{01} - c_{11}$  时, 就成为最大后验概率准则 (maximum a posteriori probability criterion)

# 贝叶斯准则以及派生贝叶斯准则

贝叶斯检测，给定各种判决代价因子，且已知各假设的先验概率条件下，使平均代价最小的检测准则。

$$\frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})}$$

$$c_{00} = c_{11} = 0$$

$$c_{01} = c_{10} = 1$$

最小平均  
错误概率  
判决准则

$$\frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)}{P(H_1)}$$

等概

最大似然  
判决准则

$$p(x|H_1) \underset{H_0}{\overset{H_1}{\gtrless}} p(x|H_0)$$

$$c_{10} - c_{00} = c_{01} - c_{11}$$

$$P(H_1|x) \underset{H_0}{\overset{H_1}{\gtrless}} P(H_0|x)$$

最大后验  
概率检测  
准则

符合最小平均错误概率准则的一定符合最大后验概率检测准则，反之不成立。

# 极小极大化准则和奈曼皮尔逊准则

贝叶斯检测，给定各种判决代价因子，且已知各假设的先验概率条件下，使平均代价最小的检测准则。

$$\frac{P(x|H_1)}{P(x|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})}$$

信源先验  
概率未知



极小化极大准则

信源先验概率及  
代价因子均未知



奈曼皮尔逊准则

# 极小极大化准则

## 贝叶斯判决准则

$$\frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} \implies \lambda(\mathbf{x}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

## 极小极大化准则

- 应用范围：

假设的先验概率未知, 判决代价因子给定

- 目的：

尽可能避免产生过分大的代价, 使极大可能代价最小化

# 极小极大化准则

- 在先验概率未知的情况下, 平均代价的性质?

平均代价是先验概率的函数

$$C = P(H_0)C(H_0) + P(H_1)C(H_1)$$

- 在先验概率未知的情况下, 进行检测的方法是:


先假设一个先验概率  $P_{lg}$ , 然后按照贝叶斯准则进行检测。

- 为尽可能降低代价, 需设计一种先验概率的假设方法, 使由此得到的检测准则的带价值与先验概率无关。

尽可能避免产生过分大的代价, 使极大可能代价最小化。

# 几种符号定义


$H_0 : x = n$  仅含噪声信号  
 $H_1 : x = A + n$  雷达检测回波信号



- **虚警概率**  $P_F \stackrel{def}{=} P(H_1|H_0)$ : False alarm, 假设  $H_0$  为真的条件下, 判决  $H_1$  成立的概率。是个假判决。
- **漏警概率**  $P_M \stackrel{def}{=} P(H_0|H_1)$ : Miss alarm, 假设  $H_1$  为真的条件下, 判决  $H_0$  成立的概率。是个遗漏的判决。
- **检测概率**  $P_D \stackrel{def}{=} P(H_1|H_1)$ : Ditection alarm, 假设  $H_1$  为真的条件下, 判决  $H_1$  成立的概率。是个正确检测的判决。

# 几种符号定义 (续)

$H_0 : x = n$  仅含噪声信号  
 $H_1 : x = A + n$  雷达检测回波信号



虚警概率  $P_F \stackrel{def}{=} P(H_1|H_0) = \int_{R_1} p(\mathbf{x}|H_0)d\mathbf{x} = 1 - \int_{R_0} p(\mathbf{x}|H_0)d\mathbf{x}$

漏警概率  $P_M \stackrel{def}{=} P(H_0|H_1) = \int_{R_0} p(\mathbf{x}|H_1)d\mathbf{x}$

检测概率  $P_D \stackrel{def}{=} P(H_1|H_1) = \int_{R_1} p(\mathbf{x}|H_1)d\mathbf{x}$

先验概率  $P_1 \stackrel{def}{=} P(H_1) = 1 - P(H_0) \stackrel{def}{=} 1 - P_0$



# 极小极大化准则—先验概率未知, 平均代价的性质

- 先验概率和代价因子已知时, 平均代价为

$$\begin{aligned} C &= P(H_0)C(H_0) + P(H_1)C(H_1) \\ &= P(H_0)(c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)) + P(H_1)(c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)) \end{aligned}$$

- 代价因子已知, 先验概率未知时, **平均代价是先验概率的函数**。 $P_1 \stackrel{\text{def}}{=} P(H_1)$

$$\begin{aligned} C(P_1) &= (1 - P(H_1))(c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)) + P(H_1)(c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)) \\ &= (1 - P_1)(c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)) + P_1(c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)) \end{aligned}$$

- 先验概率未知时, 由于贝叶斯判决门限是先验概率  $P_1$  的函数, 因此**漏警概率  $P_M$  和虚警概率  $P_F$  也是先验概率  $P_1$  的函数**。

$$\eta \stackrel{\text{def}}{=} \eta(P_1) = \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} = \frac{(1 - P_1)(c_{10} - c_{00})}{P_1(c_{01} - c_{11})} = \frac{1}{P_1(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$


$$P_M(P_1) \stackrel{\text{def}}{=} P(H_0|H_1) = \int_{R_0} p(x|H_1)dx, \quad P_F(P_1) \stackrel{\text{def}}{=} P(H_1|H_0) = \int_{R_1} p(x|H_0)dx$$

# 极小极大化准则—先验概率未知, 平均代价的性质

$$P_1 \stackrel{\text{def}}{=} P(H_1), \quad P_M(P_1) \stackrel{\text{def}}{=} P(H_0|H_1), \quad P_F(P_1) \stackrel{\text{def}}{=} P(H_1|H_0)$$

$$P(H_1|H_1) = 1 - P(H_0|H_1) = 1 - P_M(P_1)$$

$$P(H_0|H_0) = 1 - P(H_1|H_0) = 1 - P_F(P_1)$$



$$\begin{aligned} C(P_1) &= (1 - P(H_1))(c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)) + P(H_1)(c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)) \\ &= (1 - P_1)(c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)) + P_1(c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)) \\ &= (1 - P_1)(c_{00}(1 - P_F(P_1)) + c_{10}P_F(P_1)) + P_1(c_{01}P_M(P_1) + c_{11}(1 - P_M(P_1))) \\ &= (1 - P_1)c_{00} + (1 - P_1)(c_{10} - c_{00})P_F(P_1) + P_1c_{11} + P_1(c_{01} - c_{11})P_M(P_1) \\ &= c_{00} - P_1c_{00} + (c_{10} - c_{00})P_F(P_1) - P_1(c_{10} - c_{00})P_F(P_1) + P_1c_{11} + P_1(c_{01} - c_{11})P_M(P_1) \\ &= c_{00} + (c_{10} - c_{00})P_F(P_1) \\ &\quad + P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)] \end{aligned}$$


# 极小极大化准则—先验概率未知, 平均代价的性质

$$P_1 \stackrel{\text{def}}{=} P(H_1), \quad P_M(P_1) \stackrel{\text{def}}{=} P(H_0|H_1), \quad P_F(P_1) \stackrel{\text{def}}{=} P(H_1|H_0)$$

$$P(H_1|H_1) = 1 - P(H_0|H_1) = 1 - P_M(P_1)$$

$$P(H_0|H_0) = 1 - P(H_1|H_0) = 1 - P_F(P_1)$$


$$\eta \stackrel{\text{def}}{=} \eta(P_1) = \frac{1}{P_1(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$



当  $\lambda(x)$  是严格单调的概率分布随机变量时, 平均代价  $C(P_1)$  是先验概念率  $P_1$  的严格上凸函数。

$$C(P_1) = c_{00} + (c_{10} - c_{00})P_F(P_1) + P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)]$$

$$P_1 \uparrow \implies \eta \downarrow, P_M \downarrow, P_F \uparrow, P_D \uparrow, C \uparrow \sim C_{\min\max} \sim \downarrow$$



# 极小极大化准则

**目的:** 尽可能避免产生过分大的代价,使极大可能代价最小化。

- ① 猜测一个先验概率  $P_{1g}$ , 以  $\eta(P_{1g})$  为门限进行判决。
- ②  $P_{1g}$  确定,  $P_M(P_{1g})$  和  $P_F(P_{1g})$  即可确定。
- ③  $P_{1g}$  确定, 则  $C(P_1, P_{1g})$  表示与上凸函数曲线  $C(P_1)$  的切线, 如图中的直线  $b$ ,  $c$ 。


$$\eta \stackrel{\text{def}}{=} \eta(P_{1g}) = \frac{1}{P_{1g}(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$

$$C(P_1) = c_{00} + (c_{10} - c_{00})P_F(P_1) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)]$$

$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$




# 极小极大化准则

目的: 尽可能避免产生过分大的代价, 使极大可能代价最小化。

- ④ 如果实际  $P_1 = P_{1g}$ , 平均代价最小, 在直线  $b$  与  $C(P_1)$  的切点处,  $C(P_1 = P_{1g}, P_{1g})$ 。
- ⑤ 如果实际  $P_1 \neq P_{1g}$ , 比如  $P_1 = P_{11}$ , 则平均代价远大于  $C(P_1 = P_{1g}, P_{1g})$ , 在直线  $P_1 = P_{11}$  与直线  $b$  的交点处。
- ⑥ 如果猜测的先验概率为  $P_{1g}^*$ , 则无论实际的先验概率  $P_1$  为多大, 平均代价都等于  $C_{minmax}$ , 而不会产生过分大的代价。产生的代价与先验概率  $P_1$  无关。  
 $P_{1g}^*$  即是先验概率  $P_1$  最理想的猜测值。

$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) + P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$



# 极小极大化准则

先验概率未知的情况下,可猜测一个先验概率  $P_{1g}$ , 然后利用贝叶斯准则进行检测。判决门限是  $P_{1g}$  的函数, 判决区域  $R_0$  是  $P_{1g}$  的函数, 判决区域  $R_1$  是  $P_{1g}$  的函数

$$\eta \stackrel{\text{def}}{=} \eta(P_{1g}) = \frac{1}{P_{1g}(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$


$$P_M = \int_{R_0} p(x|H_1)dx \stackrel{\text{def}}{=} P_M(P_{1g}), P_F = \int_{R_1} p(x|H_0)dx \stackrel{\text{def}}{=} P_F(P_{1g})$$

$$C(P_1) = c_{00} + (c_{10} - c_{00})P_F(P_1) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)]$$

$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$



# 极小极大化准则

给定  $P_{1g}$  的条件下, 平均代价  $C(P_1, P_{1g})$  是先验概率  $P_1$  的线性函数, 若  $P_{1g} \neq P_1$ , 平均代价  $C(P_1, P_{1g})$  大于最小平均代价。

为避免产生过分大的代价, 需要猜测一种先验概率  $P_{1g}^*$ , 使得平均代价  $C(P_1, P_{1g}^*)$  不依赖于信源的先验概率  $P_1$ 。


$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) + P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$

$$\left. \frac{\partial C(P_1, P_{1g})}{\partial P_1} \right|_{P_{1g}=P_{1g}^*} = 0$$

## 极小化极大方程

$$(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}^*) - (c_{10} - c_{00})P_F(P_{1g}^*) = 0$$

**平均代价:**  $C(P_{1g}^*) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}^*)$



# 极小极大化准则

## 极小化极大方程

$$(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}^*) - (c_{10} - c_{00})P_F(P_{1g}^*) = 0$$

## 平均代价:

$$C(P_{1g}^*) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}^*)$$

### 正确判决不付出代价

$$c_{11} = c_{00} = 0$$

$$c_{01}P_M(P_{1g}^*) = c_{10}P_F(P_{1g}^*)$$

### 正确判决不付出代价, 错误判决代价因子相同

$$c_{11} = c_{00} = 0$$

$$c_{10} = c_{01} = 1$$

$$P_M(P_{1g}^*) = P_F(P_{1g}^*)$$



# 极小化极大准则的基本步骤

- ① 计算两个似然函数, 构建似然比  $\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)}$
- ② 假设判决门限  $\eta$ , 构建贝叶斯检测基本表达式
- ③ 化简成最简形式  $l(x) \underset{H_0}{\overset{H_1}{\geq}} \gamma(\eta)$
- ④ 利用极小化极大准则, 确定最终判决门限  $\gamma(\eta)$

# 贝叶斯准则例题 6

在闭启键控通信系统中,两个假设下的观测信号模型为:

$$H_0 : x = n$$

$$H_1 : x = A + n$$

其中, 噪声  $n$  是均值为零, 方差为  $\sigma_n^2$  的高斯噪声, 若两个假设的先验概率未知, 且  $c_{00} = c_{11} = 0, c_{01} = c_{10} = 1$ 。

采用极小化极大准则, 试确定检测门限, 并求最小平均错误概率。

## 贝叶斯准则例题 6: 解

解: 观测信号模型为:

$$H_0 : x = n$$

$$H_1 : x = A + n$$

### 步骤 1: 计算两个似然函数, 构建似然比

由于  $n$  是高斯分布随机变量, 因此在  $H_0$  假设下, 检测统计量  $x$  服从高斯分布, 且均值为 0, 方差为  $\sigma_n^2$ ; 在  $H_1$  假设下, 检测统计量  $x$  服从均值为  $A$ , 方差为  $\sigma_n^2$  的高斯分布。

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right) \quad p(x|H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-A)^2}{2\sigma_n^2}\right)$$
$$\lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} = \exp\left(\frac{(x^2 - (x-A)^2)}{2\sigma_n^2}\right) = \exp\left(\frac{A}{\sigma_n^2}x - \frac{A^2}{2\sigma_n^2}\right)$$

# 贝叶斯准则例题 6: 解 (续 1)

步骤 2: 假设判决门限  $\eta$ , 构建贝叶斯检测基本表达式

$$\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \stackrel{\text{def}}{=} \eta$$


$$\lambda(x) = \exp \left( \frac{A}{\sigma_n^2} x - \frac{A^2}{2\sigma_n^2} \right)$$

步骤 3: 化简成最简形式

$$x \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma_n^2 \ln \eta}{A} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$


# 贝叶斯准则例题 6: 解 (续 2)

## 步骤 4: 利用极小化极大准则, 确定最终判决门限 $\gamma$




$$\begin{aligned}
 P_F \stackrel{\text{def}}{=} P(H_1|H_0) &= \int_{\gamma}^{\infty} p(x|H_0) dx \implies Q(x) = \int_x^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= \int_{\gamma}^{\infty} \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right) dx \quad \text{by } x = \sigma_n u \\
 &= \int_{\frac{\gamma}{\sigma_n}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= Q\left(\frac{\gamma}{\sigma_n}\right)
 \end{aligned}$$

# 贝叶斯准则例题 6: 解 (续 3)



$$\begin{aligned}
 P_M &\stackrel{\text{def}}{=} P(H_0|H_1) = 1 - \int_{\gamma}^{\infty} p(x|H_1) dx \implies Q(x) = \int_x^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= 1 - \int_{\gamma}^{\infty} \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-A)^2}{2\sigma_n^2}\right) dx \quad \text{by } x = \sigma_n u + A \\
 &= 1 - \int_{\frac{\gamma-A}{\sigma_n}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= 1 - Q\left(\frac{\gamma-A}{\sigma_n}\right)
 \end{aligned}$$

# 贝叶斯准则例题 6: 解 (续 3)



$$\begin{aligned}
 P_M &\stackrel{\text{def}}{=} P(H_0|H_1) = 1 - \int_{\gamma}^{\infty} p(x|H_1) dx \implies Q(x) = \int_x^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= 1 - \int_{\gamma}^{\infty} \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-A)^2}{2\sigma_n^2}\right) dx \quad \text{by } x = \sigma_n u + A \\
 &= 1 - \int_{\frac{\gamma-A}{\sigma_n}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= 1 - Q\left(\frac{\gamma-A}{\sigma_n}\right)
 \end{aligned}$$

# 贝叶斯准则例题 6: 解 (续 4)

正确判决不付出代价, 错误判决代价因子相同时的极小化极大方程

$$c_{11} = c_{00} = 0$$

$$c_{10} = c_{01} = 1$$

$$P_M(P_{1g}^*) = P_F(P_{1g}^*)$$

$$P_F \stackrel{\text{def}}{=} P(H_1|H_0) = Q\left(\frac{\gamma}{\sigma_n}\right)$$


$$\begin{aligned} P_M \stackrel{\text{def}}{=} P(H_0|H_1) &= 1 - Q\left(\frac{\gamma - A}{\sigma_n}\right) \\ &= Q\left(-\frac{\gamma - A}{\sigma_n}\right) \end{aligned}$$

$$Q(x) = \int_x^\infty \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du$$

$$Q\left(\frac{d}{2}\right) = 1 - Q\left(-\frac{d}{2}\right)$$

根据上述极小化极大方程, 有

$$Q\left(\frac{\gamma}{\sigma_n}\right) = Q\left(-\frac{\gamma - A}{\sigma_n}\right) \Rightarrow \gamma = \frac{A}{2}$$





# 贝叶斯准则例题 6: 解 (续 5)

本例, 按照极小化极大准则, 平均错误概率为:

$$P_e = P(H_1)P(H_0|H_1) + P(H_0)P(H_1|H_0)$$

$$= P(H_1)P_M + P(H_0)P_F$$

$$= [P(H_1) + P(H_0)]P_F$$

$$= P_F = P(H_1|H_0)$$

$$= Q\left(\frac{\gamma}{\sigma}\right) = Q\left(\frac{A}{2\sigma}\right)$$

$$= Q\left(\frac{d}{2}\right)$$

by 本例的极小化极大方程  $P_M(P_{1g}^*) = P_F(P_{1g}^*)$

by  $P(H_1) + P(H_0) = 1, P_F \stackrel{def}{=} P(H_1|H_0)$

by  $\gamma = \frac{A}{2}$

by 功率信噪比  $d^2 = \frac{A^2}{\sigma^2}$

例题 5, 按照按照平均错误概率准则, 平均错误概率同上。

因此, 先验等概条件下的最小平均错误准则等价于正确判决为 0, 错误判决代价为 1 时的极小化极大准则。

# 奈曼—皮尔逊准则 (Neyman-Pearson criterion)

## ● 应用范围

假设的先验概率未知, 判决代价未知 (雷达信号检测)

## ● 目标

错误判决概率尽可能小, 正确判决概率尽可能大


## ● 实际情况

$P(H_1|H_0)$  减小时,  $P(H_1|H_1)$  也相应减小;

增加  $P(H_1|H_1)$ ,  $P(H_1|H_0)$  也随之增加。

## ● 奈曼皮尔逊检测

在虚警概率  $P_F \stackrel{\text{def}}{=} P(H_1|H_0) = \alpha$  约束条件下, 使正确判决概率 (检测概率)  $P_D \stackrel{\text{def}}{=} P(H_1|H_1)$  最大的准则。




# 奈曼—皮尔逊准则的存在性

- ① 图中, 三个判决域 ( $R_{0i}, R_{1i}$ ) 均满足错误判决概率

$$P_i(H_1|H_0) = \alpha (i = 0, 1, 2).$$

- ② 原则上判决域  $R_0$  和  $R_1$  有无限多种划分方法, 均可以保证错误判决概率  $P(H_1|H_0) = \alpha$ , 但是正确判决概率  $P(H_1|H_1)$  一般是不一样的。

- ③ 至少有一种判决域划分能使  $P(H_1|H_0) = \alpha$ , 又能使  $P(H_1|H_1)$  到达最大。



奈曼-皮尔逊检测准则是一定存在的

# 奈曼—皮尔逊准则的推导

在  $P(H_1|H_0) = \alpha$  约束条件下, 使正确判决概率  $P(H_1|H_1)$  最大的准则

等价于 (由于  $P(H_0|H_1) + P(H_1|H_1) = 1$ )

在  $P(H_1|H_0) = \alpha$  约束条件下, 使正确判决概率  $P(H_0|H_1)$  最小的准则

利用拉格朗日乘子  $\mu (\mu \geq 0)$ , 构建目标函数

$$J = P(H_0|H_1) + \mu [P(H_1|H_0) - \alpha]$$

若  $P(H_1|H_0) = \alpha$ ,  $J$  达到最小时,  $P(H_0|H_1)$  也达到最小。


漏警概率  $P(H_0|H_1)$  + 检测概率

$P(H_1|H_1) = 1$ ,

虚警概率  $P(H_1|H_0) = \alpha$


当  $J$  最小  $\Rightarrow$  漏警概率 ( $P(H_0|H_1)$ ) 最小

$\Rightarrow$  检测概率  $P(H_1|H_1)$  最大。



# 奈曼—皮尔逊准则的推导 (续)

$$\begin{aligned}
 J &= P(H_0|H_1) + \mu[P(H_1|H_0) - \alpha] \\
 &= \int_{R_0} p(x|H_1)dx + \mu \left[ \int_{R_1} p(x|H_0)dx - \alpha \right] \\
 &= \int_{R_0} p(x|H_1)dx + \mu \left[ 1 - \int_{R_0} p(x|H_0)dx - \alpha \right] \\
 &= \mu(1 - \alpha) + \int_{R_0} [p(x|H_1) - \mu p(x|H_0)] dx
 \end{aligned}$$



把使被积函数取负值的观测值  $x$  值划分给  $R_0$  区域, 而把其余的观测值  $x$  值划分给  $R_1$ , 即可保证平均代价最小, 从而使  $J$  值最小。

$$p(x|H_1) < \mu p(x|H_0)$$

判决  $H_0$  假设成立

$$p(x|H_1) \geq \mu p(x|H_0)$$

判决  $H_1$  假设成立

# 奈曼—皮尔逊准则

## 奈曼—皮尔逊准则

$$\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \mu$$

其中, 判决门限有下式确定

$$P(H_1|H_0) = \int_{R_1} p(x|H_0) dx = \int_{\mu}^{\infty} p(\lambda|H_0) d\lambda = \alpha$$

求出的  $\mu$  必满足  $\mu \geq 0$

## 贝叶斯判决准则

$$\lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} \stackrel{\text{def}}{=} \eta$$

贝叶斯准则的特例, 当  $P(H_1)(c_{01} - c_{11}) = 1, P(H_0)(c_{10} - c_{00}) = \mu$  时, 就成为奈曼—皮尔逊准则。

# 奈曼—皮尔逊准则的求解步骤

- ① 计算两个似然函数, 构建似然比  $\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \mu$
- ② 化简
- ③ 根据统计量计算  $p(l|H_0)$  和  $p(l|H_1)$
- ④ 在  $P(H_1|H_0) = \int_{R_1} p(l|H_0)dl = \alpha$  约束下, 计算判决门限

欢迎批评指正！