

信号检测与估值

段江涛

机电工程学院



2019 年 9 月

ch3. 信号检测与估计理论的基础知识

ch3-1. 统计检测理论基本概念

- 1 统计检测理论基本概念
- 2 二元信号检测
- 3 M 元信号检测
- 4 统计检测判决结果和判决概率
- 5 判决域的划分
- 6 二元信号检测—统计检测判决结果和判决概率计算
- 7 术语
- 8 统计检测基本模型


统计检测理论 (假设检验理论)

- 统计信号处理的理论基础之一
- 主要研究在受噪声干扰的随机信号中,信号的有/无或信号属于哪个状态的最佳判决的概念、方法和性能等问题。
- 数学基础——统计判决理论,又称假设检验理论

经典的信号统计检测理论

- 统计信号检测理论的基本概念
- 二元信号检测的最佳检测准则
- 信号状态的判决的方法和检测性能的分析
- M 元信号的最佳检测
- 参量信号的复合假设检验
- 序列检测

统计检测理论的基本模型: 二元信号检测的模型




信源 \Rightarrow 信源的输出称为假设

概率转移机构 \Rightarrow 将信源的输出 (假设) 以一定的
概率关系映射到整个观察空间中

观测空间 \Rightarrow 接收端所有可能观测量的集合

判决规则 \Rightarrow 将观测空间进行合理划分,
使每个观测量对应一个假设判断的方法

统计检测理论的基本模型: 二元信号检测的模型示例 1






$$H_1 : r = 1 + n$$

$$H_0 : r = -1 + n$$

n : 噪声

一维观测空间:

$$\mathbf{R} = \{-2, -1, 0, 1, 2\}$$



统计检测理论的基本模型: 二元信号检测的模型示例 2

$$H_1 : r_1 = 1 + n_1$$

$$r_2 = 1 + n_2$$


$$H_0 : r_1 = -1 + n_1$$

$$r_2 = -1 + n_2$$

n_1, n_2 : 噪声

二维观测空间:

$$\mathbf{R} = \{R_1, R_2\}$$




统计检测理论的基本模型: 二元信号检测的判决域

二元信号的检测问题,可归结为**对观察空间的划分问题**。

即按照一定的准则,将观察空间 R 分别划分为 R_0 和 R_1 两个子空间。

$$R = R_0 \cup R_1, \quad R_0 \cap R_1 = \emptyset$$



思考

如果 n 是均值为零的, 方差为 σ_n^2 的高斯随机变量, 两个假设下的观测信号模型

$$H_1 : r = 1 + n$$

$$H_0 : r = -1 + n$$

观测信号 $p(r|H_1), p(r|H_0)$ 应服从何种分布?

思考

如果 n 是均值为零的, 方差为 σ_n^2 的高斯随机变量, 两个假设下的观测信号模型

$$H_1 : r = 1 + n$$

$$H_0 : r = -1 + n$$

观测信号 $p(r|H_1), p(r|H_0)$ 应服从何种分布?

因为高斯随机变量的特点: 高斯随机变量的线性组合还是高斯随机变量。

习题 2.7: $x \sim \mathcal{N}(\mu_x, \sigma_x^2)$, 则 $(y = ax + b) \sim \mathcal{N}(a\mu_x + b, a^2\sigma_x^2)$ 。

所以, $p(r|H_1) \sim \mathcal{N}(1, \sigma_n^2), p(r|H_0) \sim \mathcal{N}(-1, \sigma_n^2)$

$$E(r|H_0) = E(1 + n) = 1 + E(n) = 1,$$

$$\text{Var}(r|H_0) = E[(r|H_0 - E(r|H_0))^2] = E[n^2] = \sigma_n^2 \implies r|H_0 \sim \mathcal{N}(1, \sigma_n^2)$$

$$E(r|H_1) = E(-1 + n) = -1 + E(n) = -1,$$

$$\text{Var}(r|H_1) = E[(r|H_1 - E(r|H_1))^2] = E[n^2] = \sigma_n^2 \implies r|H_1 \sim \mathcal{N}(-1, \sigma_n^2)$$

统计检测理论的基本模型: 二元信号检测

考虑噪声 n 为高斯噪声时的概率转移机构
观测模型为:


$$H_0: x = -A + n$$

$$H_1: x = A + n$$


概率转移:

信源输出的某一种确知信号:

- 无噪声干扰时, 将映射到观测空间中的某一点;
- 有噪声干扰时, 将以一定的概率映射到观测空间。而映射到某一点附件的概率决定于概率密度函数 $p(x|H_j)(j = 1, 2)$.




统计检测理论的基本模型: M 元信号检测



判决域划分:

$$\mathbf{R} = \bigcup_{i=0}^{M-1} R_i, R_i \cap R_j = \emptyset, (i \neq j)$$



二元信号检测—统计检测判决结果和判决概率

二元信号判决结果

判决	假设	
	H_0	H_1
H_0	$(H_0 H_0)$	$(H_0 H_1)$
H_1	$(H_1 H_0)$	$(H_1 H_1)$

$(H_i | H_j)(i, j = 0, 1)$: 在假设 H_j 为真的条件下, 判决假设 H_i 成立的结果。

二元信号判决概率

判决	假设	
	H_0	H_1
H_0	$P(H_0 H_0)$	$P(H_0 H_1)$
H_1	$P(H_1 H_0)$	$P(H_1 H_1)$


$P(H_i | H_j)(i, j = 0, 1)$: 在假设 H_j 为真的条件下, 判决假设 H_i 成立的概率。

$$H_0 : x = -A + n, \quad H_1 : x = A + n$$

$$H_0 : x_k = -A + n_k, \quad H_1 : x_k = A + n_k$$

$$k = 1, 2, \dots, N, \quad \mathbf{x} = (x_1, x_2, \dots, x_N)^T$$

$$P(H_i|H_j) = \int_{R_i} p(\mathbf{x}|H_j) d\mathbf{x}$$



$$P(H_0|H_0) = \int_{R_0} p(\mathbf{x}|H_0) d\mathbf{x}, \quad P(H_1|H_0) = \int_{R_1} p(\mathbf{x}|H_0) d\mathbf{x}$$

$$P(H_0|H_1) = \int_{R_0} p(\mathbf{x}|H_1) d\mathbf{x}, \quad P(H_1|H_1) = \int_{R_1} p(\mathbf{x}|H_1) d\mathbf{x}$$

$$\mathbf{R} = R_0 \cup R_1, \quad R_0 \cap R_1 = \emptyset, \quad \int_{\mathbf{R}} p(\mathbf{x}|H_j) d\mathbf{x} = 1$$

$$P(H_0|H_0) + P(H_1|H_0) = \int_{R_0} p(\mathbf{x}|H_0) d\mathbf{x} + \int_{R_1} p(\mathbf{x}|H_0) d\mathbf{x} = \int_{\mathbf{R}} p(\mathbf{x}|H_0) d\mathbf{x} = 1$$

$$P(H_0|H_1) + P(H_1|H_1) = \int_{R_0} p(\mathbf{x}|H_1) d\mathbf{x} + \int_{R_1} p(\mathbf{x}|H_1) d\mathbf{x} = \int_{\mathbf{R}} p(\mathbf{x}|H_1) d\mathbf{x} = 1$$


信号统计检测理论要研究的基本问题—判决域的划分

$$H_0 : x = -A + n, \quad H_1 : x = A + n$$

$$H_0 : x_k = -A + n_k, \quad H_1 : x_k = A + n_k$$

$$k = 1, 2, \dots, N, \quad \mathbf{x} = (x_1, x_2, \dots, x_N)^T$$

$$P(H_i|H_j) = \int_{R_i} p(\mathbf{x}|H_j) d\mathbf{x}$$



- 目标: 正确判决概率 $P(H_j|H_j)$ 尽可能大, 错误判决概率 $P(H_i|H_j) (i \neq j)$ 尽可能小。
- $x_0 \downarrow \implies$ 正确判决概率 $P(H_1|H_1) \uparrow$, 但另一个正确判决概率 $P(H_0|H_0) \downarrow$ 。
- $x_0 \downarrow \implies$ 错误判决概率 $P(H_0|H_1) \downarrow$, 但另一个错误判决概率 $P(H_1|H_0) \uparrow$ 。
- $x_0 \uparrow \implies$ 正确判决概率 $P(H_0|H_0) \uparrow$, 但另一个正确判决概率 $P(H_1|H_1) \downarrow$ 。
- $x_0 \uparrow \implies$ 错误判决概率 $P(H_1|H_0) \downarrow$, 但另一个错误判决概率 $P(H_0|H_1) \uparrow$ 。
- 判决域的划分影响判决概率 $P(H_i|H_j)$, 因此需要最佳划分判决域。


信号统计检测理论要研究的基本问题—判决域的划分

$$H_0 : x = -A + n, \quad H_1 : x = A + n$$

$$H_0 : x_k = -A + n_k, \quad H_1 : x_k = A + n_k$$

$$k = 1, 2, \dots, N, \quad \mathbf{x} = (x_1, x_2, \dots, x_N)^T$$

$$P(H_i|H_j) = \int_{R_i} p(\mathbf{x}|H_j) d\mathbf{x}$$



- 目标: 正确判决概率 $P(H_j|H_j)$ 尽可能大, 错误判决概率 $P(H_i|H_j) (i \neq j)$ 尽可能小。
- 判决域的划分影响判决概率 $P(H_i|H_j)$, 因此需要最佳划分判决域。
- $p(\mathbf{x}|H_j) (j = 0, 1)$: 假设 H_j 下观测信号的概率密度函数。它描述观测 (接收) 信号的统计特性。
- 按照一定的准则, 将观察空间 \mathbf{R} 分别划分为 R_0 和 R_1 两个子空间。计算判决概率 $P(H_i|H_j) (i, j = 0, 1)$ 。

二元信号检测—统计检测判决结果和判决概率计算

观测模型为:

$$H_0 : x = n$$

$$H_1 : x = A + n$$

考虑噪声 n 是均值为零, 方差为 σ^2 的高斯噪声, 且不同时刻的加性噪声之间是相互统计独立的。

接收端根据接收信号判决时, 会出现四种事件, 对应四个判决概率:

$(H_0 H_0)$	$P(H_0 H_0)$
$(H_1 H_0)$	$P(H_1 H_0)$
$(H_0 H_1)$	$P(H_0 H_1)$
$(H_1 H_1)$	$P(H_1 H_1)$

二元信号检测—统计检测判决结果和判决概率计算

观测模型为:

$$H_0 : x = -A + n$$

$$H_1 : x = A + n$$

考虑噪声 $n \sim \mathcal{N}(0, \sigma^2)$, 且不同时刻的加性噪声之间是相互统计独立的。


噪声 n 的概率密度:

$$p(n) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left(-\frac{n^2}{2\sigma^2} \right)$$

接收信号 \mathbf{x} 的统计特性可以描述为:

$$p(\mathbf{x}|H_0) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left[-\frac{(x+A)^2}{2\sigma^2} \right]$$

$$p(\mathbf{x}|H_1) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left[-\frac{(x-A)^2}{2\sigma^2} \right]$$




二元信号检测—统计检测判决结果和判决概率计算

观测模型为:

$$H_0 : x = -A + n$$

$$H_1 : x = A + n$$

考虑噪声 $n \sim \mathcal{N}(0, \sigma^2)$, 且不同时刻的
加性噪声之间是相互统计独立的。



四种判决概率的计算: $P(H_i|H_j) = \int_{R_i} p(\mathbf{x}|H_j) d\mathbf{x}$

$$P(H_0|H_0) = \int_{R_0} p(\mathbf{x}|H_0) d\mathbf{x}, \quad P(H_1|H_0) = \int_{R_1} p(\mathbf{x}|H_0) d\mathbf{x}$$

$$P(H_0|H_1) = \int_{R_0} p(\mathbf{x}|H_1) d\mathbf{x}, \quad P(H_1|H_1) = \int_{R_1} p(\mathbf{x}|H_1) d\mathbf{x}$$

$$\mathbf{R} = R_0 \cup R_1, \quad R_0 \cap R_1 = \emptyset, \quad \int_{\mathbf{R}} p(\mathbf{x}|H_j) d\mathbf{x} = 1$$

$$P(H_0|H_0) + P(H_1|H_0) = \int_{R_0} p(\mathbf{x}|H_0) d\mathbf{x} + \int_{R_1} p(\mathbf{x}|H_0) d\mathbf{x} = \int_{\mathbf{R}} p(\mathbf{x}|H_0) d\mathbf{x} = 1$$

$$P(H_0|H_1) + P(H_1|H_1) = \int_{R_0} p(\mathbf{x}|H_1) d\mathbf{x} + \int_{R_1} p(\mathbf{x}|H_1) d\mathbf{x} = \int_{\mathbf{R}} p(\mathbf{x}|H_1) d\mathbf{x} = 1$$

术语

$H_j(j = 0, 1)$: 信源输出的信号, 称为假设 H_j

$P(H_j)(j = 0, 1)$: 假设 H_j 为真的先验概率 (先验: 先于试验)

$(x|H_j)(j = 0, 1)$: 假设 H_j 下的观测信号是随机变量

$p(x|H_j)(j = 0, 1)$: 假设 H_j 下观测信号的概率密度函数

$(H_i|H_j)(i, j = 0, 1)$: 在假设 H_j 为真的条件下, 判决假设 H_i 成立的结果。

$P(H_i|H_j)(i, j = 0, 1)$: 在假设 H_j 为真的条件下, 判决假设 H_i 成立的概率。

End

End

Theorem

如果函数 $f(x)$ 在区间 $[a, b]$ 上连续, 则积分上限函数

$$\Phi(x) = \int_a^x f(t) dt$$

在 $[a, b]$ 上具有导数, 并且它的导数是

$$\Phi'(x) = \frac{d}{dx} \int_a^x f(t) dt = f(x) \quad (a \leq x \leq b)$$

Theorem

如果函数 $f(x)$ 在区间 $[a, b]$ 上连续, 则函数

$$\Phi(x) = \int_a^x f(t) dt$$

就是 $f(x)$ 在 $[a, b]$ 上的一个原函数。

Theorem

如果函数 $F(x)$ 是连续函数 $f(x)$ 在区间 $[a, b]$ 上的一个原函数, 则

$$\int_a^b f(x) dx = F(b) - F(a)$$

术语 (1)

$H_j(j = 0, 1)$: 信源输出的信号, 称为假设 H_j

$P(H_j)(j = 0, 1)$: 假设 H_j 为真的先验概率 (先验: 先于试验)

$(x|H_j)(j = 0, 1)$: 假设 H_j 下的观测信号是随机变量

$p(x|H_j)(j = 0, 1)$: 假设 H_j 下观测信号的概率密度函数

$(H_i|H_j)(i, j = 0, 1)$: 在假设 H_j 为真的条件下, 判决假设 H_i 成立的结果。

$P(H_i|H_j)(i, j = 0, 1)$: 在假设 H_j 为真的条件下, 判决假设 H_i 成立的概率。

c_{ij} : 在假设 H_j 为真的条件下, 判决假设 H_i 成立所付出的代价。

贝叶斯判决准则

判决表达式

$$\lambda(x) \underset{H_0}{\overset{H_1}{\geq}} \eta$$

$$\lambda(x) \stackrel{\text{def}}{=} \frac{p(x|H_1)}{p(x|H_0)}$$

定义为似然比函数

$$\eta \stackrel{\text{def}}{=} \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})}$$

定义为判决门限

化简 (例如对数似然比检验)

$$\ln \lambda(x) \underset{H_0}{\overset{H_1}{\geq}} \ln \eta$$

M 元信号检测模型

$$\mathbf{R} = \bigcup_{i=0}^{M-1} R_i, \quad R_i \cap R_j = \emptyset, (i \neq j)$$

最佳信号检测 \Leftarrow 正确划分观测空间 \mathbf{R} 中的各个判决域 $R_i \Leftarrow$ 最佳检测准则

两种假设先验等概 $\Rightarrow P(H_0) = P(H_1) = \frac{1}{2}$

采样样本 $x_i (i = 1, 2, \dots, N)$ 之间相互统计独立, 因此其 N 维联合概率密度能够表示成各自一维概率密度之积的形式, 即


$$p(x_1, x_2, \dots, x_N) = p(x_1)p(x_2) \cdots p(x_N) = \prod_{i=1}^N p(x_i)$$

$$n \sim \mathcal{N}(0, \sigma^2)$$

$$H_0: x = n \quad x \sim \mathcal{N}(0, \sigma^2)$$

$$H_1: x = m + n \quad x \sim \mathcal{N}(m, \sigma^2)$$

$$\text{判决表达式: } x \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma^2}{m} \ln \eta + \frac{m}{2}$$




$p(l|H_j) (j = 0, 1)$: 假设 H_j 下观测信号的概率密度函数; $r^+ = \frac{\sigma^2}{m} \ln \eta + \frac{m}{2}$; $\alpha = P(H_1|H_0)$


思考

- ① $\frac{m}{2}$ 是两个假设的中间值, $\frac{\sigma^2}{m} \ln \eta$ 为中间值的修正量, 其含义如何?
- ② 考虑 $m > 0, m < 0, m = 0$ 时, 如何构造判决表达式?

- ① $m = 0$ 时: H_0, H_1 成为一样的信号。
- ② $m \uparrow \Rightarrow$ 中间值修正量 $(\frac{\sigma^2}{m} \ln \eta) \downarrow$, r 越接近于中间值 $\frac{m}{2}$ 。
- ③ m 值越大, 更易区分两种假设, 检测性能越好。
- ④ $m > 0$ 和 $m < 0$ 下的判决表达式如下图。



$$m > 0; \quad x \underset{H_0}{\gtrless} \frac{\sigma^2}{m} \ln \eta + \frac{m}{2}$$



$$m < 0; \quad x \underset{H_0}{\gtrless} -\frac{\sigma^2}{|m|} \ln \eta - \frac{|m|}{2}$$

经过上述化简, 信号检测的判决式由似然比检验的形式, 简化为检验统计量 $l(x)$ 与检测门限 γ 相比较的形式, 形成贝叶斯检测基本表达式:

$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\geq} \frac{\sigma^2 \ln \eta}{Nm} + \frac{m}{2} \stackrel{\text{def}}{=} \gamma^+$$

检验统计量 $l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i$ 是观测信号 $x_i (i = 1, 2, \dots, N)$ 的求和取平均值的结果, 即它是 $x_i (i = 1, 2, \dots, N)$ 的函数, 是一个随机变量。

而无论是在假设 H_0 下, 还是在假设 H_1 下, $(x_i|H_0), (x_i|H_1)$ 均服从高斯分布, 因为高斯随机变量的线性组合还是高斯随机变量, 所以两种假设下的观测量 $(l|H_0), (l|H_1)$ 也是服从高斯分布的随机变量。


N 次独立采样, 样本为

$$x_i (i = 1, 2, \dots, N)$$

$$n_i \sim \mathcal{N}(0, \sigma^2)$$

$$H_0 : x_i = n_i \quad (l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$$

$$H_1 : x_i = m + n_i \quad (l|H_1) \sim \mathcal{N}(m, \frac{\sigma^2}{N})$$



$p(l|H_j) (j = 0, 1)$: 假设 H_j 下观测信号的概率密度函数; $\gamma^+ = \frac{\sigma^2 \ln \eta}{Nm} + \frac{m}{2}$; $\alpha = P(H_1|H_0)$


观测信号 ($\mathbf{x} = \{x_1, x_2, \dots, x_N\}$)

$$(\mathbf{x}|H_0) \sim \mathcal{N}(0, \sigma^2), \quad (\mathbf{x}|H_1) \sim \mathcal{N}(A, \sigma^2)$$

检验统计量 $l(\mathbf{x})$:

$$(l|H_0) \sim \mathcal{N}(0, \frac{1}{N}\sigma^2), \quad (l|H_1) \sim \mathcal{N}(A, \frac{1}{N}\sigma^2)$$

归一化后, $(l|H_j) \sim \mathcal{N}(0, 1)$



$p(l|H_j) (j = 0, 1)$: 假设 H_j 下观测信号的概率密度函数; $r^+ = \frac{\ln \eta}{d} + \frac{d}{2}$; $\alpha = P(H_1|H_0)$

判决表达式:


$$l(\mathbf{x}) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma^+$$

判决概率:(其中, 信噪比 $d^2 = \frac{NA^2}{\sigma^2}$)


$$P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right), \quad P(H_0|H_0) = 1 - Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

$$P(H_1|H_1) = Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right), \quad P(H_0|H_1) = 1 - Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

贝叶斯检测性能分析小结 (ex3 小结 2)



$p(l|H_j) (j=0,1)$: 假设 H_j 下观测信号的概率密度函数; $r^+ = \frac{\ln \eta}{d} + \frac{d}{2}$; $\alpha = P(H_1|H_0)$



$$Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} \exp(-\frac{u^2}{2}) du.$$

$Q(x)$ 是单调递减函数, 其反函数: $Q^{-1}[\bullet]$

因为 $P(H_1|H_0) = Q(\ln \eta/d + d/2) \implies \ln \eta/d = Q^{-1}[P(H_1|H_0)] - d/2$
 这样有:

$$\begin{aligned} P(H_1|H_1) &= Q(\ln \eta/d - d/2) \\ &= Q[Q^{-1}[P(H_1|H_0)] - d/2 - d/2] = Q[Q^{-1}[P(H_1|H_0)] - d] \end{aligned}$$

这说明, 当给定 $P(H_1|H_0)$ 时, $P(H_1|H_1)$ 随功率信噪比 ($d^2 = NA^2/\sigma^2$) 单调增加。

另一方面, 采样次数 $N \uparrow \implies d \uparrow, p(l|H_0), p(l|H_1)$ 的间距 $d \uparrow$, 检测性能 \uparrow 。

ex3 小结 (1)


N 次独立采样, 样本为

$$x_i (i = 1, 2, \dots, N)$$

$$n_i \sim \mathcal{N}(0, \sigma^2)$$

$$H_0 : x_i = n_i \quad (l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$$

$$H_1 : x_i = A + n_i \quad (l|H_1) \sim \mathcal{N}(m, \frac{\sigma^2}{N})$$



$p(l|H_j) (j = 0, 1)$: 假设 H_j 下观测信号的概率密度函数; $\gamma^+ = \frac{\ln \eta}{d} + \frac{d}{2}$; $\alpha = P(H_1|H_0)$

检验统计量 $l(x)$:

$$(l|H_0) \sim \mathcal{N}(0, \frac{1}{N}\sigma^2), \quad (l|H_1) \sim \mathcal{N}(A, \frac{1}{N}\sigma^2)$$

归一化后, $(l|H_j) \sim \mathcal{N}(0, 1)$

判决表达式:

$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma^+$$

判决概率:(其中, 信噪比 $d^2 = \frac{NA^2}{\sigma^2}$)

$$P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right), \quad P(H_0|H_0) = 1 - Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

$$P(H_1|H_1) = Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right), \quad P(H_0|H_1) = 1 - Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

ex3—观测量 ($l|H_0$)

性能分析:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$

统计量 $l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i$

假设 H_0 条件下, 统计量 $l(x)$ 为高斯分布, 均值和方差分别为

$$\begin{aligned} E[l|H_0] &= E\left[\frac{1}{N} \sum_{i=1}^N (x_i|H_0)\right] = E\left[\frac{1}{N} \sum_{i=1}^N n_i\right] = \frac{1}{N} \sum_{i=1}^N E[n_i] = 0 \\ \text{Var}[l|H_0] &= E[(l|H_0 - E(l|H_0))^2] = E\left[\left(\frac{1}{N} \sum_{i=1}^N n_i\right)^2\right] \\ &= \frac{1}{N^2} \sum_{i=1}^N E[n_i^2] = \frac{1}{N^2} \sum_{i=1}^N \sigma^2 = \frac{\sigma^2}{N} \end{aligned}$$

因此, $(l|H_0) \sim \mathcal{N}(0, \frac{\sigma^2}{N})$

$$p(l|H_0) = \frac{1}{\sqrt{2\pi \text{Var}[l|H_0]}} \exp\left[-\frac{(l - E[l|H_0])^2}{2\text{Var}[l|H_0]}\right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{Nl^2}{2\sigma^2}\right]$$

ex3—观测量 ($l|H_1$)

性能分析:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{def}{=} \gamma$$

统计量 $l(x) \stackrel{def}{=} \frac{1}{N} \sum_{i=1}^N x_i$

假设 H_1 条件下, 统计量 $l(x)$ 为高斯分布, 均值和方差分别为

$$\begin{aligned} E[l|H_1] &= E \left[\frac{1}{N} \sum_{i=1}^N (x_i|H_1) \right] = E \left[\frac{1}{N} \sum_{i=1}^N (A + n_i) \right] = A + \frac{1}{N} \sum_{i=1}^N E[n_i] = A \\ \text{Var}[l|H_1] &= E \left[(l|H_1 - E[l|H_1])^2 \right] = E \left[\left(\frac{1}{N} \sum_{i=1}^N (A + n_i) - A \right)^2 \right] \\ &= \frac{1}{N^2} \sum_{i=1}^N E[n_i^2] = \frac{1}{N^2} \sum_{i=1}^N \sigma^2 = \frac{\sigma^2}{N} \end{aligned}$$

因此, $(l|H_1) \sim \mathcal{N}(A, \frac{\sigma^2}{N})$

$$p(l|H_1) = \frac{1}{\sqrt{2\pi \text{Var}[l|H_1]}} \exp \left[-\frac{(l - E[l|H_1])^2}{2 \text{Var}[l|H_1]} \right] = \frac{\sqrt{N}}{\sqrt{2\pi} \sigma} \exp \left[-\frac{N(l - A)^2}{2\sigma^2} \right]$$

ex4— $l|H_0$

N 次独立采样, 样本为:

$$H_0 : x_i = 1 + n_i, i = 1, 2, \dots, N$$

$$H_1 : x_i = -1 + n_i, i = 1, 2, \dots, N$$

计算平均代价:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\gtrsim} \frac{\sigma^2 \ln \eta}{2N} = -\frac{\ln 3}{4N} \stackrel{\text{def}}{=} \gamma$$

统计量 $l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i$

假设 H_0 条件下, 统计量 $l(x)$ 为高斯分布, 均值和方差分别为

$$\begin{aligned} E[l|H_0] &= E\left[\frac{1}{N} \sum_{i=1}^N (x_i|H_0)\right] = E\left[\frac{1}{N} \sum_{i=1}^N (1 + n_i)\right] \\ &= \frac{1}{N} \sum_{i=1}^N E[(1 + n_i)] = \frac{1}{N} \sum_{i=1}^N [E(1) + E(n_i)] = \frac{1}{N} \sum_{i=1}^N [1 + 0] = 1 \\ \text{Var}[l|H_0] &= E[(l|H_0 - E[l|H_0])^2] = E\left[\left(\frac{1}{N} \sum_{i=1}^N (1 + n_i) - E(l)\right)^2\right] \\ &= E\left[\left(\frac{1}{N} \sum_{i=1}^N (1 + n_i) - 1\right)^2\right] = E\left[\left(\frac{1}{N} \sum_{i=1}^N n_i\right)^2\right] \\ &= \frac{1}{N^2} \sum_{i=1}^N E[n_i^2] = \frac{1}{N^2} \sum_{i=1}^N \sigma^2 = \frac{\sigma^2}{N} \end{aligned}$$

因此, $(l|H_0) \sim \mathcal{N}(1, \frac{\sigma^2}{N})$

$$p(l|H_0) = \frac{1}{\sqrt{2\pi \text{Var}[l|H_0]}} \exp\left[-\frac{(l - E[l|H_0])^2}{2\text{Var}[l|H_0]}\right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{N(l-1)^2}{2\sigma^2}\right]$$

ex4— $l|H_1$

N 次独立采样, 样本为:

$$H_0 : x_i = 1 + n_i, i = 1, 2, \dots, N$$

$$H_1 : x_i = -1 + n_i, i = 1, 2, \dots, N$$

计算平均代价:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\gtrsim} \frac{\sigma^2 \ln \eta}{2N} = -\frac{\ln 3}{4N} \stackrel{\text{def}}{=} \gamma$$

统计量 $l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i$

假设 H_1 条件下, 统计量 $l(x)$ 为高斯分布, 均值和方差分别为

$$\begin{aligned} E[l|H_1] &= E\left[\frac{1}{N} \sum_{i=1}^N (x_i|H_1)\right] = E\left[\frac{1}{N} \sum_{i=1}^N (-1 + n_i)\right] \\ &= \frac{1}{N} \sum_{i=1}^N E[(1 + n_i)] = \frac{1}{N} \sum_{i=1}^N [E(-1) + E(n_i)] = \frac{1}{N} \sum_{i=1}^N [-1 + 0] = -1 \\ \text{Var}[l|H_1] &= E[(l|H_1 - E[l|H_1])]^2 = E\left[\left(\frac{1}{N} \sum_{i=1}^N (-1 + n_i) - E(l)\right)^2\right] \\ &= E\left[\left(\frac{1}{N} \sum_{i=1}^N (-1 + n_i) + 1\right)^2\right] = E\left[\left(\frac{1}{N} \sum_{i=1}^N n_i\right)^2\right] \\ &= \frac{1}{N^2} \sum_{i=1}^N E[n_i^2] = \frac{1}{N^2} \sum_{i=1}^N \sigma^2 = \frac{\sigma^2}{N} \end{aligned}$$

因此, $(l|H_1) \sim \mathcal{N}(-1, \frac{\sigma^2}{N})$

$$p(l|H_1) = \frac{1}{\sqrt{2\pi \text{Var}[l|H_1]}} \exp\left[-\frac{(l - E[l|H_1])^2}{2\text{Var}[l|H_1]}\right] = \frac{\sqrt{N}}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{N(l+1)^2}{2\sigma^2}\right]$$

公式推导练习 (1)

检验统计量:

$$l(x) = \frac{1}{N} \sum_{i=1}^N (a + bn_i), i = 1, 2, \dots, N$$

其中: $n_i \sim \mathcal{N}(0, \sigma_n^2)$, 即 $E[n_i] = 0, \text{Var}[n_i] = E[(n_i - E[n_i])^2] = E[n_i^2] = \sigma_n^2$

统计量 $l(x)$ 是高斯随机变量 n_i 的线性组合, 服从高斯分布, 均值和方差分别为

$$\begin{aligned} E[l] &= E\left[\frac{1}{N} \sum_{i=1}^N (a + bn_i)\right] = \frac{1}{N} \sum_{i=1}^N E[a + bn_i] \\ &= a + \frac{b}{N} \sum_{i=1}^N E[n_i] = a \end{aligned} \quad \text{by } E[n_i] = 0$$

$$\begin{aligned} \text{Var}[l] &= E[(l - E(l))^2] = E\left[\left(\frac{1}{N} \sum_{i=1}^N (a + bn_i) - a\right)^2\right] \\ &= E\left[\left(\frac{1}{N} \sum_{i=1}^N (bn_i)\right)^2\right] = E\left[\left(\frac{b}{N} \sum_{i=1}^N n_i\right)^2\right] \\ &= \left(\frac{b}{N}\right)^2 \sum_{i=1}^N E[n_i^2] = \left(\frac{b}{N}\right)^2 N \sigma_n^2 = \frac{b^2 \sigma_n^2}{N} \end{aligned} \quad \text{by } E[n_i^2] = \sigma_n^2$$

公式推导练习 (2)

检验统计量:

$$l(x) = \frac{1}{N} \sum_{i=1}^N (m + n_i), i = 1, 2, \dots, N$$

其中: m 是常数, $n_i \sim \mathcal{N}(0, \sigma_n^2)$, 即

$$E[n_i] = 0, \text{Var}[n_i] = E[(n_i - E[n_i])^2] = E[n_i^2] = \sigma_n^2$$

统计量 $l(x)$ 是高斯随机变量 n_i 的线性组合, 服从高斯分布, 均值和方差分别为

$$\begin{aligned} E[l] &= E\left[\frac{1}{N} \sum_{i=1}^N (m + n_i)\right] = \frac{1}{N} \sum_{i=1}^N E[m + n_i] \\ &= m + \frac{1}{N} \sum_{i=1}^N E[n_i] \quad \text{by } E[n_i] = 0 \\ &= m \end{aligned}$$

$$\begin{aligned} \text{Var}[l] &= E[(l - E(l))^2] = E\left[\left(\frac{1}{N} \sum_{i=1}^N (m + n_i) - m\right)^2\right] \\ &= E\left[\left(\frac{1}{N} \sum_{i=1}^N n_i\right)^2\right] = E\left[\left(\frac{1}{N} \sum_{i=1}^N n_i\right)^2\right] \\ &= \frac{1}{N^2} \sum_{i=1}^N E[n_i^2] = \frac{1}{N^2} N \sigma_n^2 \quad \text{by } E[n_i^2] = \sigma_n^2 \\ &= \frac{\sigma_n^2}{N} \end{aligned}$$

ex5 推导(1)

两个假设下, 观测量 x 均服从高斯分布, $(x|H_0) \sim \mathcal{N}(0, \sigma^2)$, $(x|H_1) \sim \mathcal{N}(A, \sigma^2)$.

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left(-\frac{x^2}{2\sigma^2} \right)$$

$$p(x|H_1) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left[-\frac{(x-A)^2}{2\sigma^2} \right]$$

两个假设先验概率等概, 且 $c_{00} = c_{11} = 0$, $c_{10} = c_{01} = 1$, 所以似然比检验判别式为:

$$\lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} = \exp \left(\frac{2Ax - A^2}{2\sigma^2} \right) \underset{H_0}{\overset{H_1}{\geq}} \eta = 1$$

化简得判决表达式:

$$x \underset{H_0}{\overset{H_1}{\geq}} \frac{A}{2}$$

由于检验统计量 $l(x) = x$, 所以



$$p(l|H_0) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left(-\frac{l^2}{2\sigma^2} \right)$$

$$p(l|H_1) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left[-\frac{(l-A)^2}{2\sigma^2} \right]$$

ex5 推导 (2)

又因为检测判决门限 $\gamma = \frac{A}{2}$, 所以两种错误判决概率分别为

$$\begin{aligned}
 P(H_1|H_0) &= \int_{\gamma}^{\infty} p(l|H_0)dl = \int_{\frac{A}{2}}^{\infty} \left(\frac{1}{2\pi\sigma^2}\right)^{1/2} \exp\left(-\frac{l^2}{2\sigma^2}\right) dl \\
 &\stackrel{l=\sigma u}{=} \int_{\frac{A}{2\sigma}}^{\infty} \left(\frac{1}{2\pi}\right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= Q\left[\frac{A}{2\sigma}\right] = Q\left[\frac{d}{2}\right] \quad \text{by } d^2 \stackrel{\text{def}}{=} A^2/\sigma^2
 \end{aligned}$$





$p(l|H_j) (j = 0, 1)$: 假设 H_j 下观测信号的概率
密度函数; $\alpha = P(H_1|H_0)$

$Q(x) = \int_x^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) du$.
 $Q(x)$ 是单调递减函数, 其反函数: $Q^{-1}[\bullet]$

ex5 推导 (3)

$$\begin{aligned}
 P(H_0|H_1) &= \int_{-\infty}^{\gamma} p(l|H_1) dl = \int_{-\infty}^{\frac{A}{2}} \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp\left(-\frac{(l-A)^2}{2\sigma^2}\right) dl \\
 &\stackrel{l=A+u}{=} \int_{-\infty}^{-\frac{A}{2\sigma}} \left(\frac{1}{2\pi} \right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= 1 - \int_{-\frac{A}{2\sigma}}^{\infty} \left(\frac{1}{2\pi} \right)^{1/2} \exp\left(-\frac{u^2}{2}\right) du \\
 &= 1 - Q\left[-\frac{A}{2\sigma}\right] = 1 - Q\left[-\frac{d}{2}\right] = Q\left[\frac{d}{2}\right] \quad \text{by } d^2 \stackrel{\text{def}}{=} A^2/\sigma^2
 \end{aligned}$$



ex5 推导 (4)



两种错误判决概率:

$$P(H_1|H_0) = Q\left[\frac{d}{2}\right], \quad P(H_0|H_1) = Q\left[\frac{d}{2}\right]$$

其中, $d^2 \stackrel{\text{def}}{=} A^2/\sigma^2$ 。所以, 平均错误概率 P_e 为

$$\begin{aligned} P_e &= P(H_0)P(H_1|H_0) + P(H_1)P(H_0|H_1) \\ &= \frac{1}{2}Q\left[\frac{d}{2}\right] + \frac{1}{2}Q\left[\frac{d}{2}\right] = Q\left[\frac{d}{2}\right] \end{aligned}$$

$Q(x)$ 是单调递减函数, 信噪比 d 越高, 平均错误概率越小, 检测性能越好。



$p(l|H_j) (j = 0, 1)$: 假设 H_j 下观测信号的概率

$$Q(x) = \int_x^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) du.$$

最大后验概率准则

在贝叶斯准则中, 当代价因子满足: $c_{10} - c_{00} = c_{01} - c_{11}$ 时

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P(H_0)}{P(H_1)} \implies P(H_1)p(\mathbf{x}|H_1) \underset{H_0}{\overset{H_1}{\geq}} P(H_0)p(\mathbf{x}|H_0)$$

由条件概率公式, 有

$$P(H_1 | (\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})) = \frac{P((\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x}) | H_1) P(H_1)}{P(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})}$$

当 $d\mathbf{x}$ 很小时, 有

$$P((\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x}) | H_1) = p(\mathbf{x}|H_1)d\mathbf{x}, \quad P(\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x}) = p(\mathbf{x})d\mathbf{x}$$

$$P(H_1 | (\mathbf{x} \leq X \leq \mathbf{x} + d\mathbf{x})) = P(H_1 | \mathbf{x}), \text{ 从而得}$$

$$\begin{aligned} P(H_1 | \mathbf{x}) &= \frac{p(\mathbf{x}|H_1)d\mathbf{x}P(H_1)}{p(\mathbf{x})d\mathbf{x}} = \frac{p(\mathbf{x}|H_1)P(H_1)}{p(\mathbf{x})} \\ \implies P(H_1)p(\mathbf{x}|H_1) &= p(\mathbf{x})P(H_1 | \mathbf{x}) \end{aligned}$$

类似地, 可得

$$P(H_0)p(\mathbf{x}|H_0) = p(\mathbf{x})P(H_0 | \mathbf{x})$$

最大后验概率准则

$$P(H_1)p(\mathbf{x}|H_1) = p(\mathbf{x})P(H_1|\mathbf{x}), \quad P(H_0)p(\mathbf{x}|H_0) = p(\mathbf{x})P(H_0|\mathbf{x})$$

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \frac{P(H_0)}{P(H_1)} \implies P(H_1)p(\mathbf{x}|H_1) \underset{H_0}{\overset{H_1}{\geq}} P(H_0)p(\mathbf{x}|H_0)$$

$$p(\mathbf{x})P(H_1|\mathbf{x}) \underset{H_0}{\overset{H_1}{\geq}} p(\mathbf{x})P(H_0|\mathbf{x})$$


$$P(H_1|\mathbf{x}) \underset{H_0}{\overset{H_1}{\geq}} P(H_0|\mathbf{x})$$

$P(H_j|\mathbf{x}) (j = 0, 1)$ 表示已经获得观测量 \mathbf{x} 的条件下, 假设 H_j 为真时的概率, 称为后验概率。

按照最小平均代价的贝叶斯准则在代价因子满足: $c_{10} - c_{00} = c_{01} - c_{11}$ 时, 就成为最大后验概率准则 (maximum a posteriori probability criterion)

术语

- $H_1 : A + n$ 代表雷达检测有回波信号, $H_0 : x = n$ 仅含噪声信号。
- 虚警概率 $P_F \stackrel{\text{def}}{=} P(H_1|H_0)$: False alarm, 假设 H_0 为真的条件下, 判决 H_1 成立的概率。是个假判决。
- 漏警概率 $P_M \stackrel{\text{def}}{=} P(H_0|H_1)$: Miss alarm, 假设 H_1 为真的条件下, 判决 H_0 成立的概率。是个遗漏的判决。
- 漏警概率 $P_D \stackrel{\text{def}}{=} P(H_1|H_1)$: Ditection alarm, 假设 H_1 为真的条件下, 判决 H_1 成立的概率。是个正确检测的判决。



平均代价

假设 H_j 为真, 判决所付出的平均代价为:



$$C(H_j) = \sum_{i=0}^1 c_{ij} P(H_i | H_j)$$

判决 H_0 成立的代价 $C(H_0) = c_{00}P(H_0|H_0) + c_{10}P(H_1|H_0)$

判决 H_1 成立的代价 $C(H_1) = c_{01}P(H_0|H_1) + c_{11}P(H_1|H_1)$

总代价: $C = P(H_0)C(H_0) + P(H_1)C(H_1)$

平均代价 $C(P_1)$ 是先验概率 P_1 的严格上凸函数



$$\eta \stackrel{\text{def}}{=} \eta(P_1) = \frac{P(H_0)(c_{10} - c_{00})}{P(H_1)(c_{01} - c_{11})} = \frac{(1 - P_1)(c_{10} - c_{00})}{P_1(c_{01} - c_{11})} = \frac{1}{P_1(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$

$$\text{先验概率 } P_1 \stackrel{\text{def}}{=} P(H_1), \quad P_F \stackrel{\text{def}}{=} P_F(P_1) = P(H_1|H_0), \quad P_M \stackrel{\text{def}}{=} P_M(P_1) = P(H_0|H_1)$$

$$P(H_0|H_0) = 1 - P(H_1|H_0) = 1 - P_F(P_1), \quad P(H_1|H_1) = 1 - P(H_0|H_1) = 1 - P_M(P_1)$$

$$C(P_1) = c_{00} + (c_{10} - c_{00})P_F(P_1) + \quad \text{平均代价 } C(P_1) \text{ 是先验概率 } P_1 \text{ 的严格上凸函数}$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)]$$

$$P_1 \uparrow \implies \eta \downarrow, P_M \downarrow, P_F \uparrow, P_D \uparrow, C \uparrow \sim C_{\min\max} \sim \downarrow$$

直线 $C(P_1, P_{1g})$ 与上凸函数 $C(P_1)$

目的: 尽可能避免产生过分大的代价,使极大可能代价最小化。

- ① 猜测一个先验概率 P_{1g} , 以 $\eta(P_{1g})$ 为门限进行判决。
- ② P_{1g} 确定, $P_M(P_{1g})$ 和 $P_F(P_{1g})$ 即可确定。
- ③ P_{1g} 确定, 则 $C(P_1, P_{1g})$ 表示与上凸函数曲线 $C(P_1)$ 的切线, 如图中的直线 b , c 。


$$\eta = \eta(P_{1g}) = \frac{1}{P_{1g}(c_{01} - c_{11})} - \frac{c_{10} - c_{00}}{c_{01} - c_{11}}$$

$$C(P_1) = c_{00} + (c_{10} - c_{00})P_F(P_1) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_1) - (c_{10} - c_{00})P_F(P_1)]$$

$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) +$$

$$P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$




极小极大化准则

目的: 尽可能避免产生过分大的代价,使极大可能代价最小化。

- ④ 如果实际 $P_1 = P_{1g}$, 平均代价最小, 在直线 b 与 $C(P_1)$ 的切点处, $C(P_1 = P_{1g}, P_{1g})$ 。
- ⑤ 如果实际 $P_1 \neq P_{1g}$, 比如 $P_1 = P_{11}$, 则平均代价远大于 $C(P_1 = P_{1g}, P_{1g})$, 在直线 $P_1 = P_{11}$ 与直线 b 的交点处。
- ⑥ 如果猜测的先验概率为 P_{1g}^* , 则无论实际的先验概率 P_1 为多大, 平均代价都等于 C_{minmax} , 而不会产生过分大的代价。产生的代价与先验概率 P_1 无关。
 P_{1g}^* 即是先验概率 P_1 最理想的猜测值。

$$C(P_1, P_{1g}) = c_{00} + (c_{10} - c_{00})P_F(P_{1g}) + P_1[(c_{11} - c_{00}) + (c_{01} - c_{11})P_M(P_{1g}) - (c_{10} - c_{00})P_F(P_{1g})]$$



ex6


$$\begin{aligned}
 P_e &= P(H_1)P(H_0|H_1) + P(H_0)P(H_1|H_0) \\
 &= P(H_1)P_M + P(H_0)P_F \\
 &= [P(H_1) + P(H_0)]P_F \\
 &= P_F = P(H_1|H_0) \\
 &= Q\left(\frac{\gamma}{\sigma}\right) = Q\left(\frac{A}{2\sigma}\right) \\
 &= Q\left(\frac{d}{2}\right)
 \end{aligned}$$

$$\text{by } P_M(P_{1g}^*) = P_F(P_{1g}^*)$$

$$\text{by } P(H_1) + P(H_0) = 1, P_F \stackrel{\text{def}}{=} P(H_1|H_0)$$

$$\text{by } \gamma = \frac{A}{2}$$

$$\text{by 功率信噪比 } d^2 = \frac{A^2}{\sigma^2}$$




错误判决概率 (虚警概率) $P_F \stackrel{\text{def}}{=} P(H_1|H_0)$ **尽可能小**, 正确判决概率 (检测概率) $P_D \stackrel{\text{def}}{=} P(H_1|H_1)$ **尽可能大**。

漏警概率 $P(H_0|H_1)$ + 检测概率 $P(H_1|H_1) = 1$, 虚警概率 $P(H_1|H_0) = \alpha$

当 J 最小 \implies 漏警概率 $(P(H_0|H_1))$ 最小 \implies 检测概率 $P(H_1|H_1)$ 最大。

奈曼皮尔逊准则

- ① 图中, 三个判决域 (R_{0i}, R_{1i}) 均满足错误判决概率
 $P_i(H_1|H_0) = \alpha (i = 0, 1, 2)$ 。
- ② 原则上判决域 R_0 和 R_1 有无限多种划分方法, 均可以保证错误判决概率 $P(H_1|H_0) = \alpha$, 但是正确判决概率 $P(H_1|H_1)$ 一般是不一样的。
- ③ 至少有一种判决域划分能使 $P(H_1|H_0) = \alpha$, 又能使 $P(H_1|H_1)$ 到达最大。



奈曼-皮尔逊检测准则是一定存在的

ex3-7

步骤 4: 计算判决门限

$$x \underset{H_0}{\overset{H_1}{\geq}} \sigma^2 \ln \mu + \frac{1}{2} \stackrel{\text{def}}{=} \gamma$$


在错误判决概率 (虚警概率) $P_F \stackrel{\text{def}}{=} P(H_1|H_0) = 0.1$ 条件下确定判决门限

$$P_F \stackrel{\text{def}}{=} P(H_1|H_0) = \int_{\gamma}^{\infty} p(x|H_0) dx = \int_{\gamma}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx = Q(\gamma) = 0.1$$

解得: $\gamma = 1.29, \mu = 2.2$

正确判决概率 (检测概率):

$$\begin{aligned} P(H_1|H_1) &= \int_{\gamma}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x-1)^2}{2}\right] dx \\ &= \int_{1.29}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x-1)^2}{2}\right] dx = 0.386 \end{aligned}$$



判决域及判决概念率 $P(H_1|H_0)$ 和 $P(H_1|H_1)$

检测模型:

$$H_0: x = n$$


$$H_1: x = A + n$$

似然比检验的判别式:

$$\frac{1}{N} \sum_{i=1}^N x_i \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma^2 \ln \eta}{NA} + \frac{A}{2} \stackrel{\text{def}}{=} \gamma$$

统计量 $l(x)$:

$$l(x) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{i=1}^N x_i$$



判决域及判决概念率 $P(H_1|H_0)$ 和 $P(H_1|H_1)$

错误判别概率 (虚警概率):

$$P_F = P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

正确判别概率 (检测概率):

$$P_D = P(H_1|H_1) = Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

式中 $d^2 = \frac{NA^2}{\sigma^2}$, 是功率信噪比,
 $d = \sqrt{NA}/\sigma$, 称为幅度信噪比。

- 似然比检验的判别式：

$$\lambda(\mathbf{x}) = \frac{p(\mathbf{x}|H_1)}{p(\mathbf{x}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$



- 错误判别概率 (虚警概率):

$$P_F = P(H_1|H_0) = Q\left(\frac{\ln \eta}{d} + \frac{d}{2}\right)$$

- 正确判别概率 (检测概率):

$$P_D = P(H_1|H_1) = Q\left(\frac{\ln \eta}{d} - \frac{d}{2}\right)$$

- 不同的信噪比 d , 有不同的 $P_D \sim P_F$ 曲线
- 似然比函数 $\lambda(\mathbf{x})$ 超过无穷大门限 $\eta = +\infty$ 是不可能事件, $(P_D, P_F) = (0, 0)$
- $\lambda(\mathbf{x}) \geq 0, \eta = 0$ 是必然事件, $(P_D, P_F) = (1, 1)$
- 当 $\lambda(\mathbf{x})$ 是连续随机变量时, $\eta \uparrow \implies (P_D, P_F) \downarrow$



信噪比 d 是接收机的主要指标之一,因此常把接收机工作特性改成 $P_D \sim d$ 曲线,而以 P_F 作为参变量。


$$P_F = P(H_1|H_0) = Q(\ln \eta/d + d/2)$$

$$\ln \eta/d = Q^{-1}[P(H_1|H_0)] - d/2$$

$$P_D = P(H_1|H_1) = Q(\ln \eta/d - d/2)$$

$$= Q[Q^{-1}[P(H_1|H_0)] - d/2 - d/2]$$

$$= Q[Q^{-1}[P(H_1|H_0)] - d]$$



检测概率 P_D 与信噪比 d 的关系

$Q(x)$ 是递减函数, 当给定 P_F 时, P_D 随功率信噪比 ($d^2 = NA^2/\sigma^2$) 单调增加。

$$P_D = P(H_1|H_1) = \int_{\eta}^{\infty} p(\lambda|H_1)d\lambda \stackrel{\text{def}}{=} P_D(\eta)$$

$$P_F = P(H_1|H_0) = \int_{\eta}^{\infty} p(\lambda|H_0)d\lambda \stackrel{\text{def}}{=} P_F(\eta)$$

$$\frac{dP_D(\eta)}{d\eta} = -p(\eta|H_1)$$

$$\frac{dP_F(\eta)}{d\eta} = -p(\eta|H_0)$$

$$\text{by } \Phi'(x) = \frac{d}{dx} \int_a^x f(t)dt = f(x) \quad (a \leq x \leq b)$$

$$\frac{dP_D(\eta)}{dP_F(\eta)} = \frac{-p(\eta|H_1)}{-p(\eta|H_0)} = \frac{p(\eta|H_1)}{p(\eta|H_0)}$$

$$P_D(\eta) = P[(\lambda|H_1) \geq \eta]$$

$$= \int_{\eta}^{\infty} p(\lambda|H_1) d\lambda$$

$$= \int_{R_1}^{\infty} p(x|H_1) dx$$

$$= \int_{R_1}^{\infty} \lambda p(x|H_0) dx \quad \text{by } \lambda(x) = \frac{p(x|H_1)}{p(x|H_0)} \underset{H_0}{\geq} \eta$$

$$= \int_{\eta}^{\infty} \lambda p(\lambda|H_0) d\lambda$$

$$\text{by } \Phi'(x) = \frac{d}{dx} \int_a^x f(t) dt = f(x) \quad (a \leq x \leq b)$$

$$\frac{dP_D(\eta)}{d\eta} = -\eta p(\eta|H_0)$$

$$\frac{dP_D(\eta)}{dP_F(\eta)} = \frac{-p(\eta|H_1)}{-p(\eta|H_0)} = \frac{-\eta p(\eta|H_0)}{-p(\eta|H_0)} = \eta$$

$$P_D \stackrel{\text{def}}{=} P_F(P_1) = P(H_1|H_1)$$

$$P_F \stackrel{\text{def}}{=} P_F(P_1) = P(H_1|H_0)$$

$$P_M \stackrel{\text{def}}{=} P_M(P_1) = P(H_0|H_1)$$

$$= 1 - P_D$$

$$P_M(P_{1g}^*) = 1 - P_D(P_{1g}^*)$$

H_1 含随机变量 m 的似然比检验的判别式:

$$\lambda(x) = \frac{p(x|m; H_1)}{p(x|H_0)} = \frac{\int_{-\infty}^{\infty} p(x|m, H_1)p(m)dm}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \eta$$

$p(m)$ 未知

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right)$$

$$p(x|m; H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-m)^2}{2\sigma_n^2}\right)$$

$$\lambda(x) = \frac{p(x|m; H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

$$\exp\left(\frac{2mx}{2\sigma_n^2} - \frac{m^2}{2\sigma_n^2}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \eta$$

$$mx \underset{H_0}{\overset{H_1}{\gtrless}} \sigma_n^2 \ln \eta + \frac{m^2}{2}$$

$$m_0 \leq m \leq m_1, m_0 > 0$$

$$mx \underset{H_0}{\overset{H_1}{\geq}} \sigma_n^2 \ln \eta + \frac{m^2}{2}$$

$$l(x) = x \underset{H_0}{\overset{H_1}{\geq}} \frac{\sigma_n^2}{m} \ln \eta + \frac{m}{2} \stackrel{def}{=} \gamma^+$$

$$\int_{\gamma^+}^{\infty} \left(\frac{1}{2\pi\sigma_n^2} \right)^{1/2} \exp\left(-\frac{l^2}{2\sigma_n^2}\right) dl = \alpha$$

$$m_0 \leq m \leq m_1, m_1 < 0$$

$$mx \underset{H_0}{\overset{H_1}{\gtrless}} \sigma_n^2 \ln \eta + \frac{m^2}{2}$$

$$l(x) = x \underset{H_0}{\overset{H_1}{\gtrless}} - \frac{\sigma_n^2}{|m|} \ln \eta - \frac{|m|}{2} \stackrel{def}{=} \gamma^-$$

$$\int_{-\infty}^{\gamma^-} \left(\frac{1}{2\pi\sigma_n^2} \right)^{1/2} \exp\left(-\frac{l^2}{2\sigma_n^2}\right) dl = \alpha$$

若 $m_0 > 0$, m 仅取正值, 则在 $P(H_1|H_0) = \alpha$ 的约束下, $P^{(m)}(H_1|H_1)$ 是最大的, 其一致最大功效检验成立;

若 $m_1 < 0$, m 仅取负值, 则在 $P(H_1|H_0) = \alpha$ 的约束下, $P^{(m)}(H_1|H_1)$ 也是最大的。

若 $m_0 < 0, m_1 > 0$, 即 m 取值可能为正或可能为负的情况下, 无论参量信号的统计检测, 按 m 仅取正值设计, 还是按 m 仅取负值设计, 都有可能在某些 m 值下, $P^{(m)}(H_1|H_1)$ 不满足最大的要求。

例如, 按 m 取正设计信号检测系统, 当 m 为正时, $P^{(m)}(H_1|H_1)$ 最大, 但当 m 为负时, $P^{(m)}(H_1|H_1)$ 可能最小。

因此, 这种情况下不能采用奈曼-皮尔逊准则来实际最佳检测系统。

若 $m_0 < 0, m_1 > 0$, 即 m 取值可能为正或可能为负, 奈曼-皮尔逊准则不能保证 $P^{(m)}(H_1|H_1)$ 最大要求。考虑把约束条件 $P(H_1|H_0) = \alpha$ 分成两个 $\alpha/2$, 假设 H_1 的判决域由两部分组成。判决表示式为

$$|x| \underset{H_0}{\overset{H_1}{\geq}} \gamma$$

虽然双边检验比均值 m 假定为正确时的单边检验性能差, 但是比均值 m 假定为错误时的单边检验性能要好的多。因此不失为一种好的折中方法。

广义似然比检验

似然函数

$$p(x|m; H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-m)^2}{2\sigma_n^2}\right)$$

对 m 求偏导, 令结果等于零, 即

$$\frac{\partial \ln p(x|m; H_1)}{\partial m} \Big|_{m=\hat{m}_{ml}} = 0$$

解得单次观测时, m 的最大似然估计量 $\hat{m}_{ml} = x$, 于是有

$$p(x|\hat{m}_{ml}; H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{(x-\hat{m}_{ml})^2}{2\sigma_n^2}\right) \Big|_{\hat{m}_{ml}=x} = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2}$$

广义似然比检验

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right)$$

$$p(x|\hat{m}_{ml}; H_1) = \left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2}$$

代入广义似然比检验中, 有

$$\lambda(x) = \frac{p(x|m; H_1)}{p(x|H_0)} \underset{H_0}{\overset{H_1}{\geq}} \eta$$

$$\lambda(x) = \frac{\left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2}}{\left(\frac{1}{2\pi\sigma_n^2}\right)^{1/2} \exp\left(-\frac{x^2}{2\sigma_n^2}\right)} \underset{H_0}{\overset{H_1}{\geq}} \eta$$

化简得判决表示式

$$x^2 \underset{H_0}{\overset{H_1}{\geq}} 2\sigma_n^2 \ln \eta \stackrel{\text{def}}{=} \gamma^2 \implies |x| \underset{H_0}{\overset{H_1}{\geq}} \gamma$$

这正是前面讨论过的双边检验。只是前面是从奈曼-皮尔逊准则出发推导得到。而这里是从似然比检验的概念导出的, 似然函数 $p(x|m; H_1)$ 中的信号参量 m 由其最大似然估计量 \hat{m}_{ml} 代换, 所以是广义似然比检验。

title

$$H_0 = -A + n$$

$$H_1 = A + n$$

$$p(n) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left[-\frac{n^2}{2\sigma^2} \right]$$

$$p(x|H_0) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left[-\frac{(x+A)^2}{2\sigma^2} \right]$$

$$p(x|H_1) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left[-\frac{(x-A)^2}{2\sigma^2} \right]$$

欢迎批评指正！